

Московский государственный университет
имени М. В. Ломоносова

Факультет вычислительной математики и кибернетики
Кафедра исследования операций



Фостенко Олег Андреевич

**«Реконструкция относительной трехмерной позы
человека по необработанным видеоданным в условиях
отсутствия метаданных»**

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Научный руководитель:

к.ф.-м.н., доцент

Г.А.Белянкин

Москва, 2026

Содержание

Введение	4
1 Постановка задачи	5
2 Обзор существующих решений	7
2.1 2D и 3D оценка позы человека	7
2.2 RTMPose и извлечение 2D ключевых точек	10
2.3 MotionBERT и восстановление 3D позы	10
3 Реализация метода	11
3.1 Архитектура пайплайна и используемые модели	13
3.2 Входные данные	13
3.3 Реализация обнаружения объектов и оценки 2D позы	14
3.4 Реализация трекинга и выбора главной траектории	14
3.5 Реализация лифтинга и ансамблирование	17
3.6 Постобработка	21
3.7 Слияние предсказаний в мультикамерной конфигурации	24
3.7.1 Прокрустово преобразование	26
3.7.2 Синхронизация	29
3.7.3 Слияние	30
3.8 Автокалибровка и реконструкция глобальной позы	32
3.8.1 Случай установки с одной камерой	34
3.8.2 Случай установки с несколькими камерами	42
4 Эксперименты	51
4.1 Оценка 2D детекции	51
4.2 Оценка трекинга и выбора траектории	53
4.3 Оценка лифтинга, слияния и синхронизации. Примеры	53
4.4 Ограничения модели	60
4.5 Визуальные примеры реконструкции	63
Заключение	66

А Приложение	67
А.1 Производная	67
А.2 Формат Human3.6M	69
Список литературы	70

Введение

Определение ключевых точек тела человека является важным этапом для количественного анализа движений, особенно в медицинских исследованиях, связанных с нарушениями опорно-двигательного аппарата у пациентов.

В данной работе основное внимание уделяется применению методов компьютерного зрения для автоматического восстановления 2D- и 3D-координат ключевых суставных точек человека на основе видео. Для решения задачи используются state-of-the-art (SOTA) нейросетевые модели, обученные на больших датасетах с разметкой ключевых точек.

В отличие от подходов, основанных на использовании носимых устройств (сенсоров) [9; 13], предлагаемый метод не требует дополнительного оборудования. В работе рассматриваются два варианта съемки: моно- и мультикамерный (с двумя камерами). При этом оба варианта реализованы без проведения калибровки камер и точного определения их взаимного расположения. Это делает подход потенциально применимым в ситуациях с ограниченным техническим оснащением.

Основной целью данной работы является создание метода восстановления ключевых точек тела человека по видеоданным, полученным в условиях ограниченного контроля, т.е. без предварительной калибровки камер и с минимальными требованиями к оборудованию.

1 Постановка задачи

Входные данные:

Видеоряд $V = (I_1, I_2, \dots, I_T)$, где $I_t \in \mathbb{R}^{H \times W \times 3}$ – кадр в момент времени t .

Требуется реализовать пайплайн (т.е. метод) обработки видео, последовательно выполняющий следующие шаги:

1. Детекция людей в кадре

Для каждого кадра $I_t \in V$ найти ограничивающие рамки:

$$B_t = (b_t^1(I_t), \dots, b_t^{N_t}(I_t)), \quad b_t^i(I_t) = (x_t^{i,1}, y_t^{i,1}, x_t^{i,2}, y_t^{i,2}, c_t^i) \quad (1)$$

где N_t – количество обнаруженных людей, $(x_t^{i,1}, y_t^{i,1})$ и $(x_t^{i,2}, y_t^{i,2})$ – координаты левого нижнего угла и правого верхнего угла рамки на изображении соответственно, а c_t^i – степень уверенности в обнаружении.

2. Оценка позы в 2D

Для каждого обнаружения b_t^i в кадре I_t получить ключевые точки:

$$S_t^i = (p_1(I_t, b_t^i), \dots, p_K(I_t, b_t^i)), \quad p_j = (u_j, v_j, c_j) \in \mathbb{R}^3 \quad (2)$$

где K – число ключевых точек, описывающих 2D позу человека, u_j – горизонтальная координата, v_j – вертикальная координата, а c_j – уверенность в обнаружении соответствующей точки, $i = 1, \dots, N_t$.

3. Трекинг между кадрами

Построить отображение между обнаруженными позами и реальными людьми с сохранением идентичности объектов во времени, т.е. отображение, сопоставляющее идентификатор $\text{id}(i; B_1, \dots, B_t)$ каждой обнаруженной позе таким образом, чтобы тот наилучшим образом соответствовал реальным людям в кадре:

$$\text{id} : (i; B_1, \dots, B_t) \mapsto k \in \mathbb{N}, \quad \text{где } \mathbb{N} \text{ задает множество траекторий} \quad (3)$$

Значение $\text{id}(i; B_1, \dots, B_t) = k$ обозначает, что обнаружение S_t^i (и, соответственно, рамка b_t^i) относятся к траектории (человеку) с номером $k \in \mathbb{N}$. Идентификатор может зависеть от рамок (включая степень уверенности), обнаруженных на всех предыдущих и текущем кадрах, и сопоставляется индексу i , $i \in \{1, \dots, N_t\}$. Описанное отображение задано и является инъективным на каждом кадре.

Несмотря на то, что людей в кадре может быть более 1, пациент, движение которого нас интересует, лишь один. Требуется для начала выбрать пациента в кадре в автоматическом режиме, т.е. выбрать последовательность S_t^i поз с таким значением id , которое соответствует главному человеку в кадре, т.е. пациенту. Для этого вводится метрика качества траектории.

Перейдем к менее громоздким обозначениям.

Пусть $(\tau_1, \dots, \tau_N)$ — вектор траекторий, соответствующих разным людям, где

$$\tau_k = ((t_1^k, S_{t_1^k}^{i_1^k}, b_{t_1^k}^{i_1^k}), \dots, (t_{T_k}^k, S_{t_{T_k}^k}^{i_{T_k}^k}, b_{t_{T_k}^k}^{i_{T_k}^k})), t_1^k < t_2^k < \dots < t_{T_k}^k :$$

$$\forall k = 1, \dots, N \implies ((i, j) \in \{(i_1^k, t_1^k), \dots, (i_{T_k}^k, t_{T_k}^k)\} \iff id(i; B_1, \dots, B_j) = k)$$

τ_k — последовательность 2D поз, связанных с человеком с идентификатором k . Здесь N есть множество всевозможных обнаруженных id . Так, траектория τ_k есть упорядоченный набор троек вида (кадр, 2D точки, рамка), где тройка содержится в данном наборе тогда и только тогда, когда соответствующей позе определен $id = k$.

Пусть $Q : \tau \rightarrow \mathbb{R}$ — метрика качества траектории (здесь τ есть множество траекторий). Тогда под главным человеком в кадре (пациентом) подразумеваем траекторию с идентификатором:

$$k^* = \arg \max_{k=1, \dots, N} Q(\tau_k)$$

Главная траектория τ_{k^*} далее используется для 3D реконструкции и анализа движений пациента.

4. 3D реконструкция позы

Требуется преобразовать 2D ключевые точки позы в 3D координаты (т.е. выполнить т.н. лифтинг из 2D в 3D). Пусть τ_{k^*} есть траектория пациента:

$$P = (P_1, \dots, P_T) = \mathcal{R}(\tau_{k^*}) \quad (4)$$

$\mathcal{R}$ — оператор реконструкции 3D позы по 2D ключевым точкам. M — количество ключевых точек в 3D пространстве (в общем случае может отличаться от K).

5. Слияние

Построить метод, позволяющий использовать позы $P^{(1)}$ и $P^{(2)}$, предсказанные на этапе (4), для получения улучшенной итоговой оценки трехмерной позы P' в случае наличия нескольких (здесь — двух) камер.

Описанные отображения могут неявно зависеть от T – количества кадров в исходном видеоряде, от H , W – ширины и высоты видео соответственно – и, например, количества кадров в секунду, а также прочих метаданных. Тогда для входных данных с разными параметрами такого рода понимаются, вообще говоря, различные отображения.

Аналогично, стоит заметить, что в рамках практической реализации часть алгоритмов принимает в качестве входа нефиксированное число переменных, и тогда под, например, $\mathcal{R}(\tau_{k*})$ понимаются разные отображения для разных траекторий.

6. Оценка позы в мировых координатах

В условиях отсутствия метаданных получить оценку на параметры камер и положение трехмерной позы человека в мировых координатах (с точностью до параметра масштаба в силу неоднозначности) на основе полученной на предыдущих этапах относительной трехмерной позы.

Под относительной трехмерной позой здесь и далее понимается трехмерная скелетная модель человека, для которой одна из точек (в работе — ключевая точка, отвечающая тазу) неподвижна в мировых координатах, то есть закреплена в пространстве.

Слово «поза» в работе используется взаимозаменяемо со словосочетанием «скелетная модель» и подразумевает набор из координат ключевых точек тела человека.

2 Обзор существующих решений

Рассмотрим некоторые из современных методов оценки позы человека, применимых для анализа видеоданных. Укажем достоинства и недостатки, после чего поясним выбор конкретных моделей для данной работы.

2.1 2D и 3D оценка позы человека

Методы обработки видео, позволяющие извлечь 3D точки, можно разделить на две группы. Одни явно используют 2D точки, разделяя обработку видео на два этапа: извлечение двумерных и затем восстановление (лифтинг) трехмерных координат [24]. Другие же методы используют видеопоследовательность непосредственно для извлечения трехмерных координат [18; 21], используя 2D координаты только на этапе обучения, но не предсказания. Хотя бывают и модели, которые используют гибридный подход, принимая

во внимание как визуальные признаки, так и двумерные координаты [41].

Есть методы, использующие различные конфигурации камер: предполагающие наличие сразу нескольких камер или же только одной.

Нейросетевые модели, предназначенные для задач восстановления как 2D, так и 3D координат, используют различную архитектуру. Модели, показывающие наилучшие результаты на бенчмарках, например, связанных с датасетами Human3.6M [17], MPI-INF-3DHP [5] и 3DPW [31], все имеют трансформерную архитектуру. Под точностью в данном абзаце подразумевается погрешность в предсказанных трехмерных координатах. Для оценки моделей, предсказывающих 2D точки (которые затем подаются на вход моделям, восстанавливающим 3D точки), используются иные бенчмарки. Однородность же связана с тем, что нейросеть-трансформер способна учитывать контекст, длительные зависимости в последовательности данных, что необходимо при обработке видео, где множество предыдущих и последующих кадров тесно связаны с текущим. Иные методы также могут использовать нейросети и других архитектур. Популярное решение VideoPose3D [2] использует сверточные нейросети. По точности оно, впрочем, уступает более современным методам.

Бенчмарки позволяют количественно оценить предсказательную способность моделей.

Например, метод MotionBERT [24], используемый в данной работе – это модель, принимающая только двумерные координаты, но не визуальные признаки. Данная модель является SOTA на бенчмарке, связанном с датасетом Human3.6M, в котором видеокамера стационарна.

Подзадачей в рамках извлечения 3D точек из видео является обнаружение 2D точек. Существует множество методов, предназначенных для этого. Нейронные сети, лежащие в основе этих методов, также имеют различную архитектуру. Например, нейросеть-трансформер лежит в основе ViTPose [40] – точного, но требовательного к ресурсам метода извлечения 2D координат. Часто в решениях используются сверточные нейросети. В качестве примера: HRNet [8] и используемый в рамках этой работы RTMPose [32].

Одной из проблем выбора 2D модели является наличие готовых решений, осуществляющих детекцию точек в подходящем формате. Например, в одном из самых популярных форматов двумерной позы COCO [22] отсутствуют некоторые

ключевые точки, которые может принять на вход модель, осуществляющая лифтинг 2D координат в 3D. Существует целое множество форматов 2D позы. Например: MPII [1], COCO-Wholebody [43], AIC [20], Halpe26 [4]. Одни модели лучше совместимы с наиболее популярным форматом 3D позы Human3.6M, а другие – хуже. Поэтому в рамках задачи извлечения 3D точек следует учитывать совместимость форматов 2D и 3D точек, т.к. отсутствие (неверное расположение) некоторых может значительно ухудшить результаты.

Почти все существующие решения предлагают формат COCO (упомянутые ViTPose, HRNet, RTMPose в т.ч.). Формат Halpe26 наилучшим образом совместим с Human3.6M, в котором предсказывают модели, осуществляющие лифтинг 2D в 3D точки, но решения, которые могут детектировать в данном формате, уже не столь распространены. Современные методы позволяют в том числе обучиться на точках одного формата, а выводить другие, но в данном случае неизбежен процесс потери информации.

Задача трекинга также имеет множество решений (в т.ч. готовых), хорошо обобщаемых на произвольные видеопоследовательности. Например, OC-SORT [27], BoT-SORT [3], BoostTrack++ [37] – это решения, показывающие высокий результат на бенчмарке MOT17 [23]. В случае задачи извлечения 3D из видео с пациентом качество трекинга, если оно выше некоторого порога, оказывает лишь незначительное влияние на результат – хотя в этой работе использован SOTA-алгоритм, различия хорошо видны лишь при наличии окклюзий (ситуаций, когда один объект заслоняет собой другой), чего нет в данных, использованных в данной работе.

В итоге, стоит заметить, что есть множество решений поставленных задач 1-5 по отдельности, однако при решении нескольких из этих задач для in-the-wild видео (т.е. видео не из датасета, на котором обучалась модель) готовые алгоритмы часто комбинируют решения неэффективно. Например, для SOTA-алгоритма из этой работы [24] существует сразу несколько реализаций с различными недостатками. В их числе: отсутствие трекинга, что делает невозможным применение в условиях поставленной задачи, отсутствие ансамблирования, неэффективная нормализация данных (т.е. произведенная в неоптимальных местах пайплайна), детекция в несовместимом формате и использование устаревших моделей на этапе получения 2D точек. Последнее, как показала практика, значительно распространено в готовых реализациях алгоритмов лифтинга (в частности, [8; 10; 24]).

2.2 RTMPose и извлечение 2D ключевых точек

RTMPose: Real-Time Multi-Person Pose Estimation based on MMPose [32] — это модель для оценки позы человека, которая может работать в реальном времени, разработанная в рамках фреймворка MMPose. Основана на так называемом top-down подходе (сначала производится детекция людей с помощью внешнего детектора (например, RTMDet), а затем — оценка позы для каждого человека отдельно) с использованием сверточной нейросети с архитектурой CSPNeXt и алгоритма SimCC (который позволяет получить точки с субпиксельной точностью: так, вместо дискретных значений, координаты точек задаются действительными числами).

Данная модель выбрана, т.к. позволяет достичь высокой точности при относительно небольшом потреблении ресурсов, что делает ее пригодной для поставленной задачи. Главное достоинство — возможность детекции в формате Halpe26, что обеспечивает максимальную совместимость результатов (2D точек) с форматом входных данных моделей для лифтинга в 3D. Для сравнения, метрика средней точности (AP) на бенчмарке COCO для RTMPose-l, использованного в данной работе, составляет 76.6%, в то время как популярный фреймворк для 2D детекции AlphaPose демонстрирует 72.6% [32] на своей лучшей модели (AlphaPose представляет набор моделей).

2.3 MotionBERT и восстановление 3D позы

Модель MotionBERT [24] — это SOTA (на бенчмарке Human3.6M) модель для восстановления трехмерной позы человека на основании 2D точек, полученных некоторым алгоритмом для извлечения 2D точек с одной камеры (т.е. модель выполняет лифтинг). В то время как 2D детекция и трекинг не столь сильно влияют на конечный результат (3D точки) в зависимости от поведения на бенчмарках, выбор модели для лифтинга, которая наилучшим образом показывает себя на соответствующих бенчмарках — это необходимость. Практика показала, что модели, лишь немногим уступающие MotionBERT [2; 10; 18], показывают визуально значительно худшие результаты.

MotionBERT построена на основе двухпоточкового пространственно-временного трансформера (Dual-stream Spatio-temporal Transformer (DSTformer)), который обрабатывает пространственные и временные зависимости между суставами скелета с помощью двух параллельных потоков — пространственного и временного. Такая

структура позволяет модели учитывать как геометрические связи между суставами, так и динамику движения во времени.

MotionBERT предлагает возможность использования окон различной ширины (например: 27, 81, 243), в которых учитывается контекст. При отсутствии ограничений по ресурсам разумнее выбрать большее окно, т.к. при большем окне улучшается способность модели учитывать взаимосвязи.

Данная модель также обучена работать с сильно зашумленными данными, что позволяет готовым реализациям использовать шумную 2D детекцию с удовлетворительным конечным результатом, но в рассматриваемом случае используется точная 2D детекция, что уменьшает итоговую ошибку.

Формат входных данных для модели – Human3.6M. Этот формат отличается от Halpe26, используемого в 2D детекции, лишь присутствием средней точки на позвоночнике (при отображении остальных точек позы из Halpe26 в соответствующие точки Human3.6M). Результаты оценки двумерной позы готовыми моделями показали, что те из них, что изначально предлагают детекцию в желаемом формате (Human3.6M), демонстрируют значительно худшие результаты на in-the-wild видео, чем RTMPose, оценивающий 2D позу в Halpe26. Был сделан вывод о целесообразности использования формата без точки на позвоночнике, но с лучшей точностью детекции.

В сравнении с популярным методом VideoPose3D извлечения 3D точек из видео, MotionBERT показал среднюю ошибку 39.2 по MPJPE (среднее отклонение расположения суставов) на окне из 243 кадров при ошибке 46.8 у VideoPose3D на бенчмарке Human3.6M [24] с использованием протокола, подразумевающего 2D детекцию перед предсказанием 3D позы.

3 Реализация метода

Опишем реализацию выбранного подхода к восстановлению 3D позы человека из 2D ключевых точек, извлеченных с видео. Рассмотрим архитектуру пайплайна, включающего модели для 2D детекции и 3D лифтинга, формат используемых входных и выходных данных, а также методы обработки многокамерных данных для повышения точности восстановления трехмерных координат.




Рис. 1: Схема пайплайна.

3.1 Архитектура пайплайна и используемые модели

Для извлечения 3D точек пациента из необработанного видео в рамках пайплайна (т.е. метода обработки видео) используется несколько последовательных этапов:

Для начала при помощи алгоритма RTMPose и встроенного детектора для каждого кадра I_t извлекаются рамки $B_t = (b_t^1(I_t), \dots, b_t^{N_t}(I_t))$ (задача 1) и двумерные позы $S_t^i = (p_1(I_t, b_t^i), \dots, p_K(I_t, b_t^i))$ (задача 2).

Далее при помощи алгоритма трекинга BoostTrack++ обнаруженные позы сопоставляются людям в кадре. Таким образом, каждому человеку соответствует траектория

$$\tau_k = ((t_1^k, S_{t_1^k}^{i_1^k}, b_{t_1^k}^{i_1^k}), \dots, (t_{T_k}^k, S_{t_{T_k}^k}^{i_{T_k}^k}, b_{t_{T_k}^k}^{i_{T_k}^k})), t_1^k < t_2^k < \dots < t_{T_k}^k$$

По метрике Q , отображающей траектории τ_k в числа из $\mathbb{R}$, автоматически выбирается поза, соответствующая пациенту (задача 3).

На следующем этапе выбранной 2D позе сопоставляется 3D поза с помощью модели для лифтинга 2D координат в трехмерное пространство MotionBERT. Модель получает на вход траекторию τ_{k^*} и использует информацию на некотором окне (т.е. контекст) для восстановления трехмерной позы (задача 4):

$$P = (P_1, \dots, P_T) = \mathcal{R}(\tau_{k^*})$$

Пайплайн допускает использование нескольких моделей, работающих с пересекающимися окнами, для увеличения точности и плавности получаемой позы. В конце также возможна постобработка для приведения масштаба обнаруженной 3D позы на всей последовательности кадров. На выходе получается 3D поза, из которой можно извлечь кинематические характеристики движения для дальнейшей работы с ними. При наличии нескольких камер, пайплайн также допускает слияние результатов, полученных с нескольких видео, в более точную позу (задача 5).

Схематично описанная последовательность шагов изображена на рис. 1.

3.2 Входные данные

Входные данные представляют собой набор необработанных видеозаписей (датасет), на которых пациент передвигается по коридору по направлению от камеры или к камере. Для части пациентов приведены видео, в которых оба процесса запечатлены

одновременно на две камеры, расположенные по обеим сторонам коридора соответственно. В случае мультикамерной конфигурации отсутствует информация о внешних и внутренних параметрах конфигурации (взаимное расположение камер, фокусное расстояние), а также отсутствует синхронизация во времени.

3.3 Реализация обнаружения объектов и оценки 2D позы

Как детекция объектов на видео (и извлечение рамок), так и оценка двумерной позы произведены при помощи инструментов фреймворка MMPose [45].

В автоматическом режиме сначала при помощи встроенного детектора обнаруживаются объекты и извлекаются ограничивающие рамки, затем реализованный в рамках фреймворка алгоритм RTMPose извлекает 2D координаты. На выходе имеются как рамки B_t , включая степень уверенности, так и 2D позы S_t^i .

Реализация произведена на языке Python с использованием API MMPose.

3.4 Реализация трекинга и выбора главной траектории

Трекинг произведен при помощи средств языка Python и фреймворка boxmot [44], предоставляющего API к реализации алгоритма BoostTrack++. На этапе трекинга алгоритм сопоставляет набору рамок и 2D точек id, после чего соответствующие рамки и позы объединяются в траектории τ_k так, чтобы в рамках одной траектории были все позы, соответствующие одному конкретному идентификатору.

Опишем метрику Q , присваивающую траектории число из отрезка $[0, 1]$. $(\tau_1, \dots, \tau_N)$ — вектор траекторий, полученный при помощи трекинга, где, как и ранее, траектория есть массив из номеров кадров, рамок и поз, соответствующих конкретному идентификатору:

$$\tau_k = ((t_1^k, S_{t_1^k}^{i_1^k}, b_{t_1^k}^{i_1^k}), \dots, (t_{T_k}^k, S_{t_{T_k}^k}^{i_{T_k}^k}, b_{t_{T_k}^k}^{i_{T_k}^k})), t_1^k < t_2^k < \dots < t_{T_k}^k :$$

$$\forall k = 1, \dots, N \implies ((i, j) \in \{(i_1^k, t_1^k), \dots, (i_{T_k}^k, t_{T_k}^k)\} \iff \text{id}(i; B_1, \dots, B_j) = k)$$

Приведем интуитивные соображения, в соответствии с которыми будет задана метрика для конкретной траектории τ_k :

1) У каждой рамки $b_t^i(I_t) = (x_t^{i,1}, y_t^{i,1}, x_t^{i,2}, y_t^{i,2}, c_t^i)$ в каждом кадре I_t есть степень уверенности в детекции c_t^i . Эта характеристика учитывает, в числе прочего, удаление

человека от камеры, а также наличие окклюзий. Чем человек важнее в кадре, тем, ожидается, уверенность в его детекции на протяжении всего видео больше. Требуется учитывать уверенность на всех кадрах. Разумно задать ее как 0 в кадрах, где данный человек не был обнаружен. Пусть $\forall t \in \{1, \dots, T\}$ если $t \in \{t_1^k, \dots, t_{T_k}^k\}$, то это значит, что в данном кадре обнаружена некоторая поза S_t^i с идентификатором k , тогда обозначим соответствующую уверенность c_t^i как $\tilde{c}_t^k$. Иначе $\tilde{c}_t^k = 0$. Т.е.:

$$\tilde{c}_t^k = \begin{cases} c_t^i, & \text{если в кадре } t \text{ есть некоторая поза } S_t^i \text{ с присвоенным ей идентификатором } k, \\ 0, & \text{иначе.} \end{cases}$$

Тогда средняя уверенность на всем видео равна:

$$\bar{c}^k = \frac{1}{T} \sum_{t=1}^T \tilde{c}_t^k$$

Уверенность $\tilde{c}_t^k$ на каждом кадре лежит на отрезке от 0 до 1 $\implies \bar{c}^k \in [0, 1]$.

2) Ожидается, что главный в видео человек будет присутствовать в как можно большем количестве кадров.

Зададим функцию-индикатор присутствия человека в кадре a_t^k как:

$$a^k = \frac{T_k}{T}$$

Т.е. a^k равен доле кадров видео, где данный человек был обнаружен. $a^k \in [0, 1]$.

3) На важность человека в видео также непременно влияет размер рамки. Чем больше рамка, тем ближе человек к камере, и наоборот. Ожидается, что более важный в кадре человек будет находиться ближе к камере. На основании этого, для каждого кадра введем функцию $\tilde{b}_t^k$, зависящую от рамки, принимающую значения в $[0, 1]$. На кадрах, где человек не обнаружен, присвоим функции значение 0:

$$\tilde{b}_t^k = \begin{cases} \frac{(x_t^{i,2} - x_t^{i,1})^2 + (y_t^{i,2} - y_t^{i,1})^2}{H^2 + W^2}, & \text{если в кадре } t \text{ есть поза } S_t^i \text{ с соотв. идентификатором } k, \\ 0, & \text{иначе.} \end{cases}$$

H и W – высота и ширина видео соответственно (разрешение), а координаты взяты из соответствующего представления рамки: $b_t^i(I_t) = (x_t^{i,1}, y_t^{i,1}, x_t^{i,2}, y_t^{i,2}, c_t^i)$.

В качестве размера рамки взята диагональ. Диагональ рамки не может быть больше диагонали изображения. Отсюда, $\tilde{b}_t^k \in [0, 1]$.

Соответственно, введем среднее:

$$\bar{b}^k = \frac{1}{T} \sum_{t=1}^T \tilde{b}_t^k, \quad \bar{b}^k \in [0, 1]$$

4) Наконец, стоит заметить, что почти всегда главный в кадре человек находится ближе к центру кадра. Получается, разумно ввести меру того, насколько человек близко к центру. За центр кадра возьмем $(\frac{W}{2}, \frac{H}{2})$. Как и ранее, на кадрах, где человек не попадает в кадр, зададим соответствующий функционал как минимально возможный (ноль). Наибольшее удаление от центра – углы изображения.

Центр рамки расположен в точке: $(\frac{x_t^{i,1}+x_t^{i,2}}{2}, \frac{y_t^{i,1}+y_t^{i,2}}{2})$.

Тогда метрика удаления от центра $\tilde{d}_t^k$ в кадре равна:

$$\tilde{d}_t^k = \begin{cases} 1 - \frac{\left(\frac{W}{2} - \frac{x_t^{i,1}+x_t^{i,2}}{2}\right)^2 + \left(\frac{H}{2} - \frac{y_t^{i,1}+y_t^{i,2}}{2}\right)^2}{\left(\frac{H}{2}\right)^2 + \left(\frac{W}{2}\right)^2}, & \text{если в кадре } t \text{ есть поза } S_t^i \text{ с идентификатором } k, \\ 0, & \text{иначе.} \end{cases}$$

$\tilde{d}_t^k \in [0, 1]$, причем значение 1 принимается при совпадении центра рамки с центром изображения, а 0 – на максимальном удалении от центра.

Соответственно, среднее:

$$\bar{d}^k = \frac{1}{T} \sum_{t=1}^T \tilde{d}_t^k, \quad \bar{d}^k \in [0, 1]$$

В итоге, имеем 4 значения $\bar{c}^k, a^k, \bar{b}^k, \bar{d}^k$, причем все из них лежат в $[0, 1]$.

Зададим итоговую метрику качества траектории Q как:

$$Q(\tau_k) = w_1 \bar{c}^k + w_2 a^k + w_3 \bar{b}^k + w_4 \bar{d}^k$$

В более общем случае можно было бы учесть не только рамки b_t^i , но и позы S_t^i . Например, так можно лучше учесть окклюзии. В рассматриваемом случае в этом нет необходимости.

В данной работе используется лишь небольшой датасет, потому веса можно выбрать равными:

$$w_1 = w_2 = w_3 = w_4 = \frac{1}{4}$$

При наличии большого датасета с разметкой на нем, веса $w_1, \dots, w_4$ можно задать с учетом максимизации количества верно классифицированных объектов (т.е. так, чтобы на максимальном числе видео главный человек определялся правильно).

После этого остается лишь выбрать такой идентификатор k , что на нем достигается максимум $Q(\cdot)$, т.е.:

$$k^* = \arg \max_{k=1, \dots, N} Q(\tau_k)$$

Заданная таким образом метрика с соответствующими весами позволяет определить главного человека (пациента) верно на всех видео, использованных в рамках данной работы (т.е. на 100% объектов).

Траектория пациента τ_{k^*} далее используется для 3D реконструкции.

3.5 Реализация лифтинга и ансамблирование

Для восстановления 3D позы применялся исходный код, опубликованный вместе с оригинальной статьей MotionBERT [24], с модификациями, внесенными в рамках данной работы. Был использован интерфейс модели, доступный через командную строку, а также средства языка Python. На этапе лифтинга алгоритм сопоставляет траектории τ_{k^*} набор трехмерных координат $P = (P_1, \dots, P_T)_{j=1}^M$

На практике было получено, что MinMax-нормализация, выполняемая на окнах из кадров по отдельности, эффективнее, чем MinMax-нормализация, либо выполненная на всем видео, либо не выполняемая в принципе. Под MinMax-нормализацией здесь подразумевается приведение данных к значениям из $[0, 1]$ одинаково по всем осям (с сохранением пропорций), основываясь на максимальном и минимальном значениях на заданном диапазоне кадров. Соответственно, на каждом окне из кадров выполнена нормализация на, вообще говоря, разное значение константы нормализации.

Выбран размер окна 243, т.к. на бенчмарке MotionBERT показывает наилучшие результаты именно с этим размером окна.

Выбрано количество базовых моделей ансамбля 3 с шагом в 81 кадр. Т.е., возвращаясь к рис. 1, $243 = kn$, где k взят 3. Соответственно, $n = 81$. В экспериментах это позволило достичь плавного перехода при переключении между окнами. Пересечение окон между моделями, отличающимися по входным данным на шаг n относительно друг от друга, есть $(k - 1)n = 162$ кадра. Взят равномерный шаг, поскольку при неравномерном шаге пересечение между окнами различно по ширине; отсюда потенциально неравномерное качество восстановления позы.

Иными словами, модель 1 восстанавливает позу на окне от кадра 1 до 243 (оба

включительно), далее на окне от 244 до 486 (оба включительно) и т.д. со сдвигом 243; модель 2 – на кадрах от 82 до 324 (оба включительно) и т.д.; модель 3 – на кадрах от 163 до 405 (оба включительно) и т.д. Сохраним эти обозначения далее.

Таким образом, на каждом кадре есть 3 предсказания, а модели при предсказании имеют различный контекст, что позволяет добиться на практике получения положительного эффекта ансамблирования (улучшение качества результатов после слияния).

Практика показала, что предсказания модели на кадре, в котором отсутствует контекст с одной из сторон (например, на кадре 1 или кадре 243 для одной из моделей ансамбля), имеют значительную погрешность. Желательно, чтобы в любой момент времени веса, с которыми берутся предсказания моделей ансамбля, были таковы, чтобы больший вес был у той модели, которая имеет наибольший двусторонний контекст, ведь архитектура DSTFormer (на которой основан MotionBERT) имеет ту же особенность, что и BERT [6], где отсутствие контекста с одной из сторон существенно ухудшает результаты предсказания.

Т.е. следует выбрать веса $w_1(t), w_2(t), w_3(t)$, с которыми суммируются предсказания P_t^1, P_t^2, P_t^3 моделей 1, 2, 3 в рамках ансамбля соответственно на данном кадре I_t , зависящими от времени, причем следующим образом:

Пусть $\{\tilde{t}_1^i, \dots, \tilde{t}_{243}^i\}$ – окно, на котором предсказывает модель с номером i в настоящий момент. Здесь момент времени $\tilde{t}_k^i$ соответствует кадру $I_{\tilde{t}_k^i}$. Тогда пускай текущий момент времени t равен $\tilde{t}_{k_1}^1, \tilde{t}_{k_2}^2, \tilde{t}_{k_3}^3$ соответственно. Считаем, что модель работает только с окнами длины 243, а $T \geq 243$. Под контекстом модели j на кадре t будем подразумевать:

$$context_t^j = \min \{\tilde{t}_{k_j}^j - \tilde{t}_1^j, \tilde{t}_{243}^j - \tilde{t}_{k_j}^j\} = \min \{k_j - 1, 243 - k_j\}$$

Отсюда, желаемое:

$$w_i(t) > w_j(t) \text{ при условии } context_t^i > context_t^j \quad (5)$$

Нетрудно заметить, что данное условие не выполнено при $w_1 = w_2 = w_3 = \frac{1}{3}$. Пример: при заданных весах на кадре 243:

$$context_{243}^1 = 0, \quad context_{243}^2 = 81, \quad context_{243}^3 = 80$$

Однако, $w_1(243) = w_2(243)$ при том, что $context_{243}^1 < context_{243}^2$

Отсюда необходимость зависимости от времени t .

Но этого условия недостаточно. На практике при переключении между окнами предсказания получаются значительно различными, что устраняет плавность итогового результата. Требуется ее сохранить, задав веса на граничных кадрах (отличных от начального $t = 1$ и, возможно, конечного $t = T$) меньшими некоторого порога ε . На основе экспериментальных данных выбирается

$$\varepsilon = 0.02, \text{ при условии } w_1 + w_2 + w_3 = 1 \quad (6)$$

Утверждение.

$$\text{Пусть } G(t) = \exp \left(-\frac{1}{2} \left(\frac{((t-1) \bmod 243) - 121}{40} \right)^2 \right)$$

Здесь $\bmod$ обозначает остаток от деления.

Тогда веса

$$\begin{aligned} w_1(t) &= \frac{G(t)}{G(t) + G(t-81) + G(t-162)} \\ w_2(t) &= \frac{G(t-81)}{G(t) + G(t-81) + G(t-162)} \\ w_3(t) &= \frac{G(t-162)}{G(t) + G(t-81) + G(t-162)} \end{aligned}$$

удовлетворяют условиям (5), (6) для кадров $t = 163, \dots, (T - T \bmod 81) - 162$.

Доказательство. $\forall t \ G(t_1) = G(t_2)$, если $t_1, t_2 \geq 1$ и $|(t_1 - 1) \bmod 243 - 121| = |(t_2 - 1) \bmod 243 - 121|$. Также $G(t) = G(t + 243)$ при $t \geq 1$.

Отсюда:

$$w_1(243) = w_1(244) = w_1(486) = w_1(487) = \dots$$

Численные значения функции: $G(81) \approx 0.5914$, $G(162) \approx 0.6065$, $G(243) \approx 0.0103$

$$w_1(243) = \frac{G(243)}{G(243) + G(162) + G(81)} \approx 0.0085 < \varepsilon$$

Аналогично,

$$w_2(243 + 81) = w_2(244 + 81) = w_2(486 + 81) = \dots = w_1(243) < \varepsilon$$

$$w_3(162) = w_3(163) = w_3(243 + 162) = w_3(244 + 162) = \dots = w_1(243) < \varepsilon$$

Здесь значения t взяты так, что в любой момент времени доступны предсказания всех трех моделей.

Получили (6). Далее рассмотрим (5):

Заметим, что выражение $|(t-1) \bmod 243 - 121|$ для $t \in \{1, \dots, 243\}$ тем более, чем далее от t центр окна 1-243; $|(t-81-1) \bmod 243 - 121|$ для $t \in \{1+81, \dots, 243+81\}$ тем более, чем далее от t центр окна $(1+81)-(243+81)$, и аналогично для $|(t-162-1) \bmod 243 - 121|$.

Вспомним, что $context_t^j$ равен минимальному расстоянию до края обрабатываемого окна от кадра t .

Найдем взаимосвязь между $context_t^1$ и $g(t) = |(t-1) \bmod 243 - 121|$ для модели 1 на окне из кадров с номерами 1-243:

$$context_t^1 = \min \{t-1, 243-t\}$$

$$\text{Для } t \in \{1, \dots, 122\} \implies g(t) = 121 - (t-1) = 121 - context_t^1$$

$$\text{Для } t \in \{122, \dots, 243\} \implies g(t) = (t-1) - 121 = -(243-t) + 121 = 121 - context_t^1$$

Значит, чем больше $context_t^1$, тем меньше значение $(t-1) \bmod 243 - 121$, а значит, тем больше $G(t)$ на соответствующих t . Осталось показать, что при приближении к центру окна $G(t)$ возрастает не медленнее, чем сумма в знаменателе (и при удалении убывает не медленнее, чем сумма в знаменателе).

Вычисления производной $w_1(t)$ приведены в приложении А.1.

В центре окна ($t = 122$) она равна нулю, слева ($82 \leq t < 122$) для любого t она больше нуля, а справа ($162 \geq t > 122$) меньше. Следовательно, эта функция достигает на центральном кадре максимума. Так, вес $w_1(t)$ тем меньше, чем дальше от центра находится текущий кадр (т.е. чем меньше контекст). Для $1 \leq t \leq 81$ производная строго больше 0, а для $163 \leq t \leq 243$ — строго меньше, причем для кадров $t = 81, t = 82, t = 162, t = 163$ верны соотношения:

$$w_1(81) < w_1(82), w_1(162) > w_1(163).$$

Функция $w_2(t)$ на окне $t \in \{1+81, \dots, 243+81\}$ равна $w_1(t-81)$. Для функции $w_3(t)$ верно аналогичное свойство.

Из полученного ранее:

$$G(t) = \exp \left(-\frac{1}{2} \left(\frac{121 - context_t^1}{40} \right)^2 \right)$$

и $w_1(t)$ убывает/возрастает одновременно с $G(t)$ и имеет экстремум в той же точке, что и $G(t)$.

Так, верно, что чем больше контекст $context_t^i$, тем меньше для данной модели i расстояние от центра окна и тем больше вес $w_i(t)$. Т.к. для моделей i и j $121 - context_t^i$ равен $121 - context_t^j$ на равных расстояниях от центра, а веса $w_i(t)$ и $w_j(t)$ одинаковы и увеличиваются/уменьшаются одновременно вместе с увеличением/уменьшением контекста, то, стало быть, при $context_{t_1}^i > context_{t_2}^j \iff w_i(t_1) > w_j(t_2)$

Это, в частности, доказывает свойство (5).

□

В рамках технической реализации, веса для t , не попавших в рассматриваемое окно ($t \notin \{163, \dots, (T - T \bmod 81) - 162\}$), выбраны следующим образом: в $t \in \{1, \dots, 81\}$ веса моделей 2, 3 приняты равными нулю; в $t \in \{82, \dots, 162\}$ вес модели 3 принят нулевым, а вес модели 2 задан как $w_2(t) = \frac{G(t-81)}{G(t)+G(t-81)}$; в точках же $t \in \{T - T \bmod 81 - 162 + 1, \dots, T\}$ веса заданы как в утверждении, однако модели используют лишь часть окна для предсказания, имея в каждый момент времени урезанный контекст. На практике выбранные таким образом веса позволяют достичь плавного перехода для всех t , не попавших в рассмотрение: между $t = 81, t = 82$, между $t = 162, t = 163$ и аналогичных t из $\{T - T \bmod 81 - 162, \dots, T\}$.

На выходе данного этапа получается трехмерная поза:

$$P_t = w_1(t)P_t^1 + w_2(t)P_t^2 + w_3(t)P_t^3 \quad (7)$$

Здесь за P_t^i обозначено предсказание i -й модели ансамбля на кадре I_t .

MotionBERT позволяет получить позу относительно некоторой точки позы (например, одной из точек таза). Для восстановления абсолютных координат (т.е. с учетом движения человека по некоторой траектории в пространстве) могут использоваться иные модели. Для рассматриваемой задачи выполнено восстановление именно относительной позы.

3.6 Постобработка

MotionBERT предсказывает трехмерную позу с сохранением эффекта уменьшения/увеличения размера позы в двумерном случае (чем дальше от камеры пациент, тем он кажется меньше). Поэтому после предсказания трехмерной позы

ансамблем моделей MotionBERT координаты позы нормализуются (ведь в реальности изменения размера позы нет – у человека постоянный размер). В случае одной камеры это может потребоваться для дальнейшего автоматического извлечения кинематических характеристик движения. В случае нескольких камер, это необходимо перед применением метода слияния предсказаний, полученных с помощью видов с нескольких (двух) камер.

Модель трехмерной позы Human3.6M включает 17 точек позы. Обозначим за $d(t; i, j)$ евклидово расстояние между точками позы с номерами i и j в рамках предсказанных трехмерных координат P_t в момент времени t . Назовем «основными расстояниями» вектор:

$$d(t) = (d(t; i_1, j_1), \dots, d(t; i_n, j_n))^T \quad (8)$$

где $\forall k (i_k, j_k)$ принадлежит некоторому множеству D пар точек (причем перечислены все элементы D , т.е. $|D| = n$). Детали формата Human3.6M, а также множество D указаны в приложении A.2.

Формально, под нормализацией понимается следующее: Пусть задан вектор весов

$$\tilde{w} = (\tilde{w}_1, \dots, \tilde{w}_n)^T$$

Полагаем:

$$\tilde{w}_i = \text{const}, \quad \sum_{i=1}^n \tilde{w}_i = 1.$$

Под значением усреднения в кадре I_t понимаем значение функции:

$$\text{norm}(t) = \tilde{w}^T d(t)$$

Под процессом нормализации (или нормализацией) понимаем переход к нормализованным координатам:

$$\tilde{P}_t = \frac{P_t}{\text{norm}(t)} \quad (9)$$

где $P_t \in \mathbb{R}^{17 \times 3}$ состоит из 17 точек, задаваемых тремя числами; и под делением подразумеваем операцию умножения матрицы P_t на скаляр $\frac{1}{\text{norm}(t)}$. Заметим, что $\forall t \text{ norm}(t) > 0$ в силу природы данных: в рамках выполнения работы было замечено, что точки никогда не накладываются друг на друга. Если бы это предположение не было выполнено, то можно было бы принять $\tilde{P}_t = \frac{P_t}{\text{norm}(t) + \varepsilon}$, однако в технической реализации нормализация выполнена именно согласно (9).

Как пример, позу можно нормализовать на сумму всех основных расстояний с одинаковыми весами, т.е. $\tilde{w}_i = \frac{1}{n}$.

Рассмотрим алгоритм нормализации, при котором минимизируется сумма дисперсий основных расстояний:

Пусть

$$no\bar{r}m = \frac{1}{T} \sum_{t=1}^T \tilde{w}^T d(t)$$

Положим, соответственно

$$\tilde{d}(t; i, j) = \frac{1}{\tilde{w}^T d(t)} \cdot no\bar{r}m \cdot d(t; i, j)$$

Умножение на $no\bar{r}m$ необходимо, т.к. в противном случае основные расстояния с бóльшим средним будут давать бóльшие значения усреднения, а отсюда, ожидается, большие веса будут у наибольших расстояний. Желаемым же является сравнение дисперсий при, в целом, одном и том же масштабе позы вне зависимости от выбора весов $\tilde{w}$.

T – общее число кадров. Тогда дисперсия расстояния между точками (i_k, j_k) :

$$\text{Var}_t(\tilde{d}(t; i_k, j_k)) = \frac{1}{T} \sum_{t=1}^T \left(\tilde{d}(t; i_k, j_k) - \frac{1}{T} \sum_{s=1}^T \tilde{d}(s; i_k, j_k) \right)^2 \quad (10)$$

Задача оптимизации формулируется следующим образом:

$$J(\tilde{w}) = \sum_{k=1}^n \text{Var}_t(\tilde{d}(t; i_k, j_k)) \rightarrow \min_{\tilde{w} \in W}, \quad W = \{\tilde{w} : \sum_{i=1}^n \tilde{w}_i = 1, \tilde{w}_i \geq 0\} \quad (11)$$

Функция $J(\tilde{w})$ определена на $(n-1)$ -мерном симплексе. Это компакт.

Далее, $g(\tilde{w}) = \tilde{d}(t; i, j) = \frac{1}{\tilde{w}^T d(t)} \cdot no\bar{r}m \cdot d(t; i, j)$ – это непрерывная по $\tilde{w}$ функция (в знаменателе стоит непрерывная по $\tilde{w}$ функция, которая по предположению не обращается в 0). $\tilde{d}(t; i_k, j_k) - \frac{1}{T} \sum_{s=1}^T \tilde{d}(s; i_k, j_k)$ также непрерывна как разность непрерывной функции и конечной суммы непрерывных. Отсюда, $\text{Var}_t(\tilde{d}(t; i_k, j_k))$ также непрерывна, и, следовательно, оптимизируемый функционал $J(\tilde{w})$ непрерывен.

По теореме Вейерштрасса о непрерывной функции на компакте, $J(\tilde{w})$ достигает своих верхней и нижней грани. Значит, решение задачи оптимизации существует, однако, вообще говоря, может быть не единственным.

Заметим, что у $J(\tilde{w})$ есть непрерывные первая и вторая производные (т.е. градиент и матрица Гессе): $\tilde{d}(t; i_k, j_k)$ есть константа, деленная на линейную функцию, и

имеет непрерывные вторые частные производные. Аналогичным свойством обладает $\text{Var}_t(\tilde{d}(t; i_k, j_k))$, которая является суммой квадратов функций с непрерывными вторыми частными производными. Наконец, отсюда, $J(\tilde{w})$ обладает тем же свойством.

Применим алгоритм SLSQP [19] для численного решения этой задачи. Этот алгоритм способен учитывать ограничения, присутствующие в данной задаче, и подходит для задач с нелинейным функционалом с приведенными выше свойствами.

В таблице 1 представлены результаты сравнения по коэффициенту детерминации (R^2) двух вещественнозначных функций от t :

1) функции $\frac{\tilde{w}^T d(t)}{\frac{1}{T} \sum_{t=1}^T \tilde{w}^T d(t)}$ и 2) функции $\frac{\tilde{w}_0^T d(t)}{\frac{1}{T} \sum_{t=1}^T \tilde{w}_0^T d(t)}$ где $\tilde{w}_0^T = (\frac{1}{n}, \dots, \frac{1}{n})$, а $\tilde{w}$ есть полученное алгоритмом решение поставленной задачи оптимизации. Значения приведены для трех различных видео из датасета.

Таблица 1: Сравнение функций нормализации.

Номер видео	Значение метрики R^2
1	0.9998573606931374
2	0.9999895523366403
3	0.9999718075015277

В рамках экспериментов наблюдается высокая степень согласованности функции нормализации на сумму основных расстояний с одними и теми же весами и функции нормализации, выбранной в соответствии с рассмотренной задачей оптимизации.

В технической реализации выполнена нормализация с одинаковыми весами.

После выполнения нормализации получаем итоговый результат предсказания 3D позы с одной камеры. Далее из полученных данных можно извлечь кинематические характеристики движения.

3.7 Слияние предсказаний в мультикамерной конфигурации

При наличии видов с нескольких камер выполняется та же последовательность действий, что была описана ранее, для видео, снятых с каждой из камер.

Итак, имеем $\tilde{P}_{t_1}^{(1)}$ и $\tilde{P}_{t_2}^{(2)}$ – предсказания 3D позы из видео с камеры 1 и с камеры 2 для каждых t_1 и t_2 . В поставленной задаче камеры не откалиброваны, т.е. неизвестны

внешние и внутренние параметры конфигурации, необходимые для применения метода триангуляции восстановления трехмерной позы. Но в этих условиях все еще можно скомбинировать виды с нескольких камер.

Также в поставленной задаче камеры несинхронизированные, что означает, что видео 1 сдвинуто на некоторое неизвестное небольшое число кадров относительно видео 2. Под небольшим числом кадров подразумевается, что съемка начиналась и останавливалась вблизи момента времени, определенного некоторым внешним маркером (пример: пациент дошел до конца зала или пациент поднял руку), и при этом разница во времени между началом съемки видео 1 и началом съемки видео 2, а также концом съемки видео 1 и концом съемки видео 2 не превосходит T_{cap} кадров.

Для приведенного далее метода автоматической синхронизации видео во времени необходимо, чтобы одно видео было вложено в другое во времени. При наличии предположения о максимальной разнице в кадрах между началами и концами съемки с нескольких камер соответственно вложенность можно обеспечить путем вырезания первых и последних T_{cap} кадров из одного из видео (пусть это будет видео 1). Далее считаем, что видео 1 вложено во времени в видео 2. Пусть видео 2 начинается с $t = 1$ и кончается $t = T$, а видео 1 начинается с $t = \tilde{t} \geq 1$ и кончается $t = \tilde{T} \leq T$.

Чтобы синхронизировать видео, необходимо определить, насколько похожи во времени две последовательности из поз $(\tilde{P}_1^{(1)}, \dots, \tilde{P}_{\tilde{T}-\tilde{t}+1}^{(1)})$ и $(\tilde{P}_1^{(2)}, \dots, \tilde{P}_T^{(2)})$ при различных сдвигах одной последовательности относительно другой во времени. Предполагается, что максимальная похожесть при сдвиге t^* будет означать, что t^* есть истинная задержка во времени одного видео относительно другого, выраженная в кадрах.

Вводится метрика похожести двух видеопоследовательностей при различных сдвигах. Так, сначала $\tilde{t}$ (время начала видео 1) принимается равным единице, а $\tilde{T}$ – равным длине видео 1; после этого вычисляется метрика похожести видео 1 на видео 2, как если бы оба видео начинались одновременно. На втором шаге $\tilde{t} = 2$, а $\tilde{T}$ принимается равным длине видео 1 плюс единица; вычисляется метрика похожести видео 1 на видео 2, как если бы более короткое видео 1 начиналось позже видео 2 на один кадр. Описанная процедура далее повторяется для остальных сдвигов, при которых $\tilde{T} \leq T$ при вложенности видео 1 в видео 2 во времени. На выходе получается последовательность значений метрики для всевозможных сдвигов видео 1 относительно видео 2. Заметим, что снятие ограничения

на вложенность потребовало бы введения метрики для кадров, на которых сравнение невозможно, что потенциально ухудшило бы результаты автоматической синхронизации.

Упомянутая метрика похожести основана на наложении одной позы на другую с помощью т.н. прокрустово преобразования [34]. На каждом шаге одна из поз наилучшим возможным образом накладывается на другую позу, и оценивается качество этого наложения. В последующем слиянии предсказаний также используется схожий метод.

3.7.1 Прокрустово преобразование

Пусть даны две матрицы $A, B \in \mathbb{R}^{n \times d}$. Требуется найти ортогональную матрицу $R \in \mathbb{R}^{d \times d}$, число $s \in \mathbb{R}$ и вектор переноса $\mathbf{t}_{\text{trans}} \in \mathbb{R}^d$ такие, что на них достигается

$$\min_{s, R, \mathbf{t}_{\text{trans}}} \|B - sAR - \mathbf{1}\mathbf{t}_{\text{trans}}^T\|_F^2 \quad (12)$$

где $\mathbf{1} \in \mathbb{R}^n$ — вектор из единиц, и R удовлетворяет условию ортогональности: $R^T R = I$.

$\mathbf{1}$ и $\mathbf{t}_{\text{trans}}$ есть вектор-столбцы.

Применительно к поставленной изначально задаче, A и B есть соответственно трехмерные позы, предсказанные по видео 1 и видео 2. Одна поза сдвинута, повернута и, возможно, отличается по размеру относительно другой, поэтому для наложения поз требуется повернуть одну из них в пространстве с помощью преобразования R , сдвинуть на $\mathbf{t}_{\text{trans}}$ и масштабировать на число s так, чтобы она накладывалась на другую оптимальным образом.

Решение этой задачи было предложено П. Шенеманном и Р. Кэрроллом [35]. Его можно найти в явном виде:

1) Матрицы центрируются по столбцам:

$$\begin{aligned} \bar{A} &= \frac{1}{n} A^T \mathbf{1}, \quad \bar{B} = \frac{1}{n} B^T \mathbf{1}, \\ A_0 &= A - \mathbf{1} \bar{A}^T, \quad B_0 = B - \mathbf{1} \bar{B}^T. \end{aligned}$$

2) Из сингулярного разложения произведения матриц A_0^T, B_0 находится матрица R :

$$\begin{aligned} M &= A_0^T B_0 \\ M &= U \Sigma V^T \\ R &= UV^T \end{aligned} \quad (13)$$

Если $\det(R) < 0$, то имеем преобразование с отражением, но отражения не подходят по задаче. В этом случае последний столбец матрицы V умножается на -1 . Это позволяет дополнить алгоритм так, чтобы учитывать ограничение $\det(R) = 1$ [25; 39].

3) Находится оптимальный вектор переноса:

$$\mathbf{t}_{\text{trans}} = \frac{1}{n}(B - sAR)^T \mathbf{1} = \bar{B} - sR^T \bar{A} = (\bar{B}^T - s\bar{A}^T R)^T.$$

4) В общем случае далее находится оптимальный масштаб s , однако для трехмерных поз ранее была выполнена нормализация, а потому в подборе этого параметра нет необходимости. В таком случае s полагается равным единице [35].

Итоговое приближение:

$$B \approx AR + \mathbf{1}\mathbf{t}_{\text{trans}}^T.$$

В случае более чем двух матриц (т.е. более чем двух камер) формулируется похожая задача, и решение затем находится из итерационного процесса [14]. В рассматриваемом случае, однако, в датасете отсутствуют видео, записанные в конфигурации с более чем двумя камерами.

Матрицы A и B могут быть, вообще говоря, произвольного размера (но такими, что размер обеих совпадает), потому в задаче сравнения поз можно брать сразу целое окно из кадров, выполняя конкатенацию матриц, представляющих позу в кадре, так, чтобы увеличивалось количество строк. Т.е. решаемая задача будет рассматриваться как задача подбора преобразования, наиболее качественно приближающего набор трехмерных точек 1 к набору трехмерных точек 2, где оба набора выражены матрицами из $\mathbb{R}^{n \times d}$, $n = k \cdot 17$ (17 – число точек в формате Human3.6M), $d = 3$, k – число кадров в окне.

Техника подбора оптимального преобразования по окну из нескольких кадров на практике позволила получить более плавное выравнивание поз с уменьшенным влиянием случайных шумов и особенностей отдельных кадров в сравнении с покадровым выравниванием.

Итак, метрика, описывающая разницу между последовательностями поз из видео 1 и 2 при смещении видео 1 на $\tilde{t} - 1$ кадров вперед во времени относительно начала видео 2, задается следующим образом (считаем начало видео 2 моментом времени $t = 1$):

Пусть, как и ранее, $\tilde{P}_{t_1}^{(1)}$ и $\tilde{P}_{t_2}^{(2)}$ есть нормализованные предсказания трехмерных поз, полученных с видео 1 и видео 2 в моменты времени t_1 и t_2 соответственно. Введем матрицы, включающие предсказания на окне из кадров длины k :

$$M_{t_1} = \begin{pmatrix} \tilde{P}_{t_1}^{(1)} \\ \tilde{P}_{t_1+1}^{(1)} \\ \vdots \\ \tilde{P}_{t_1+k-1}^{(1)} \end{pmatrix} \in \mathbb{R}^{17k \times 3}, \quad N_{t_2} = \begin{pmatrix} \tilde{P}_{t_2}^{(2)} \\ \tilde{P}_{t_2+1}^{(2)} \\ \vdots \\ \tilde{P}_{t_2+k-1}^{(2)} \end{pmatrix} \in \mathbb{R}^{17k \times 3}$$

Для матриц M_{t_1} и N_{t_2} можно найти матрицу поворота R и вектор переноса $\mathbf{t}_{\text{trans}}$ такие, что на них достигается минимум:

$$\min_{R, \mathbf{t}_{\text{trans}}} \|N_{t_2} - M_{t_1} R - \mathbf{1} \mathbf{t}_{\text{trans}}^T\|_F^2$$

Пусть рассматривается смещение видео 1 на $\tilde{t} - 1$ кадров относительно начала видео 2. С шагом единица обрабатываются окна из поз:

$$M_j, N_{\tilde{t}+j} : \quad j = 1, \dots, (\tilde{T} - \tilde{t} + 1) - k + 1$$

Обозначим за $R_j^{\tilde{t}}$ и $(\mathbf{t}_{\text{trans}})_j^{\tilde{t}}$ соответственно оптимальные матрицу поворота и вектор смещения в задаче

$$\min_{R, \mathbf{t}_{\text{trans}}} \|N_{\tilde{t}+j} - M_j R - \mathbf{1} \mathbf{t}_{\text{trans}}^T\|_F^2$$

На каждом шаге находятся оптимальные поворот и смещение позы из видео 1 так, чтобы та максимально качественно накладывалась на позу из видео 2 на окне из кадров. Поскольку окно состоит из нескольких кадров, а шаг равен единице, у окон есть пересечение. Для каждого кадра $t = 1, \dots, \tilde{T} - \tilde{t} + 1$ усредняем выровненные позы по всем окнам, содержащим этот кадр:

$W_t = \{j : j \leq t \leq j + k - 1\}$ – количество окон, в которых есть поза на данном кадре t ,

$$\hat{P}_t^{(1)}(\tilde{t}) = \frac{1}{|W_t|} \sum_{j \in W_t} \left(\tilde{P}_t^{(1)} R_j^{\tilde{t}} + \mathbf{1} ((\mathbf{t}_{\text{trans}})_j^{\tilde{t}})^T \right) \quad (14)$$

Заметим, что здесь производится умножение не набора поз на матрицу поворота, как ранее, а лишь позы в одном кадре.

Так, с помощью прокрустового преобразования получили набор поз $(\hat{P}_1^{(1)}(\tilde{t}), \dots, \hat{P}_{\tilde{T}-\tilde{t}+1}^{(1)}(\tilde{t}))$. Эти позы, в числе прочего, зависят от рассматриваемого смещения $\tilde{t} - 1$. Неформально, это набор нормализованных поз из видео 1 $(\tilde{P}_1^{(1)}, \dots, \tilde{P}_{\tilde{T}-\tilde{t}+1}^{(1)})$, преобразованный с сохранением расстояний и углов и сдвинутый в пространстве так, чтобы наилучшим образом подходить под набор поз $(\tilde{P}_{\tilde{t}}^{(2)}, \dots, \tilde{P}_{\tilde{T}}^{(2)})$ из видео 2.

3.7.2 Синхронизация

Метрика ошибки для данного смещения $\tilde{t}-1$ задается как среднее евклидова расстояния между позами из видео 2 и усредненными выровненными позами из видео 1:

$$\text{score}(\tilde{t}) = \frac{1}{(\tilde{T} - \tilde{t} + 1) \cdot 17} \sum_{t=1}^{\tilde{T}-\tilde{t}+1} \sum_{j=1}^{17} \left\| (\tilde{P}_{t+\tilde{t}-1}^{(2)})_j - (\hat{P}_t^{(1)}(\tilde{t}))_j \right\|_2, \quad (15)$$

где за $(\tilde{P}_t^{(2)})_j$ и $(\hat{P}_t^{(1)}(\tilde{t}))_j$ обозначены строки матриц соответственно $(\tilde{P}_t^{(2)})$ и $(\hat{P}_t^{(1)}(\tilde{t}))$ с номерами j . Т.е. метрика есть отклонение точек позы 1 относительно соответствующих им точек позы 2, усредненное по всем кадрам и по всем точкам.

На рис. 2 и рис. 3 представлены результаты вычисления метрики на двух парах различных видео. Первая пара видео представляет из себя сцену, где человек исполняет разнообразные, непериодичные движения (видео взято из датасета [29]). Вторая пара видео запечатлел человека, идущего в одном направлении на протяжении всего видео (периодичное движение).




Рис. 2: Пример вычисления метрики для первой пары видео. Первое видео пары обрезано на 400 кадров с начала и с конца. Реальное смещение первого видео относительно второго есть -33 кадра. Точка минимума совпадает с реальным смещением.




Рис. 3: Пример результата вычисления метрики для второй пары видео. Первое видео пары обрезано на 40 кадров с начала и с конца. Реальное смещение первого видео относительно второго есть 54 кадра. Точка минимума совпадает с реальным смещением.

Заметим, что в силу периодичности движения в случае второй пары значения метрики имеют осциллирующий характер; локальные минимумы соответствуют смещению примерно на длительность (в кадрах) одного полного цикла движения (один левый и один правый шаг), а максимумы, соответственно, смещению на половину длительности цикла. График построен на основе видео с частотой 30 кадров в секунду. Смещение выражено в кадрах. Выравнивание произведено с помощью прокрустового преобразования с окном в 100 кадров.

Для оценки смещения видео 1 относительно видео 2 вычисляется:

$$t^* = \arg \min_{\tilde{t}} \text{score}(\tilde{t})$$

Если движение является периодичным и расположение камер субоптимально (в случае пары, представленной на рис. 3, оптические оси камер примерно совпадают, камеры направлены друг на друга, человек находится вблизи отрезка в пространстве, соединяющего камеры), автоматическая синхронизация затруднена. В подобных вырожденных случаях эксперт вручную выбирает один из минимумов.

Далее считаем смещение восстановленным.

3.7.3 Слияние

Слияние применяется для уточнения относительной трехмерной позы в случае, когда триангуляция (см. раздел 3.8.2) затруднительна в силу вырожденного расположения камер. В качестве результата автоматической синхронизации видео имеем две последовательности поз:

$$(\hat{P}_1^{(1)}(t^*), \dots, \hat{P}_{\tilde{T}-\tilde{t}+1}^{(1)}(t^*)) \quad \text{и} \quad (\tilde{P}_{\tilde{t}}^{(2)}, \dots, \tilde{P}_{\tilde{T}}^{(2)})$$

Пусть, для простоты обозначений:

$$P_t^{(1)} := \hat{P}_t^{(1)}(t^*), \quad P_t^{(2)} := \tilde{P}_{\tilde{t}+t}^{(2)}, \quad t = 1, \dots, \tilde{T} - \tilde{t} + 1$$

$$l := \tilde{T} - \tilde{t} + 1$$

l – длина обоих видео после синхронизации и обрезки видео 2 по длине видео 1.

Требуется скомбинировать набор поз $(P_1^{(1)}, \dots, P_l^{(1)})$ и $(P_1^{(2)}, \dots, P_l^{(2)})$.

В случае множества камер, расположенных случайным образом, при неизвестной структуре движения, позы усредняются с весами $\frac{1}{m}$, где m – число камер. Усреднение – это универсальное решение, применимое для любой задачи подобного типа.

В случае используемого в рамках данной работы датасета структура движения и приблизительное расположение камер известны, следовательно нельзя исключать, что веса могут быть подобраны динамически так, чтобы уменьшить ошибку предсказания по сравнению с одинаковыми константными весами. Известно, что камеры расположены по двум концам коридора. Человек на одном видео движется по направлению к выбранной камере, а на другом, соответственно – от этой камеры. Оба видео заканчиваются, когда человек находится вблизи противоположной камеры. Ошибка предсказания в среднем больше, когда человек находится дальше от камеры. Если ввести динамические веса на основе близости позы к камерам, то можно было бы ожидать уменьшение ошибки, вызванной ухудшением качества детекции и восприятия глубины на расстоянии. В то же время присвоение большего веса одной модели непременно уменьшит эффект устранения шума при объединении независимых наблюдений.

Эксперименты показали, что положительный эффект от ансамблирования превосходит негативный эффект от уменьшения качества предсказания на расстоянии (конкретно на датасете, использованном в этой работе), и веса $w_1(t) = w_2(t) = \frac{1}{2}$ дают наилучший результат.

Так, финальная оценка трехмерной позы человека в конфигурации с двумя камерами и в условиях описанной природы данных:

$$\begin{aligned} P_t &= w_1(t)P_t^{(1)} + w_2(t)P_t^{(2)} \\ w_1(t) &= w_2(t) = \frac{1}{2} = \text{const}, \end{aligned} \tag{16}$$

и последовательность, описывающая позу,

$$P = (P_1, \dots, P_l)$$

может быть использована для извлечения кинематических характеристик движения.

Таким образом, описанный подход, основанный на применении прокрустова преобразования для выравнивания поз между видеопоследовательностями, позволяет синхронизировать данные с нескольких камер и объединять их в единую трехмерную оценку позы.

Описанный подход может быть обобщен на большее число камер.

3.8 Автокалибровка и реконструкция глобальной позы

Для любой установки с множеством камер (возможно, с одной камерой) у каждой камеры есть так называемые внешние параметры и внутренние параметры. Внешние параметры задают расположение камер в пространстве (как одна камера повернута и перемещена относительно других). Внутренние параметры описывают свойства камеры, отвечающие за формирования изображения, например фокусное расстояние, положение главной точки изображения, соответствующей пересечению оптической оси с плоскостью изображения, коэффициент перекоса, а также, возможно, оптические искажения. В отсутствие метаданных все из этих параметров заранее неизвестны. Но даже в этом случае можно описать метод оценки трехмерной позы человека в мировых координатах. Будем называть ее глобальной (абсолютной) позой, то есть позой, скелетная модель для которой не закреплена в пространстве. Именно такая реконструкция позволяет ответить на вопрос, каково было реальное движение человека по сцене при съемке.

В этом разделе предлагается метод восстановления внутренних и внешних параметров камер в установках с одной камерой и установках с бóльшим их числом и метод восстановления глобальной трехмерной позы человека по видеопоследовательностям, полученным на таких установках.

Опишем простейшую модель камеры.

Камера формирует двумерное изображение трехмерного мира. Пусть Ox — горизонтальная ось, Oy — вертикальная ось на плоскости, на которой формируется изображение.

Для любой камеры внутренние параметры задаются матрицей

$$K = \begin{pmatrix} f_x & s & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix},$$

где c_x, c_y — координаты главной точки соответственно по Ox и по Oy , s — коэффициент перекоса.

Для современных камер, в том числе, например, камер смартфонов, на практике можно рассмотреть упрощенную модель, считая, что точка (c_x, c_y) расположена в центре

изображения, коэффициент перекося равен нулю и $f_x = f_y$ [15; 38].

Разрешение, в отличие от многих других метаданных, известно. Обозначим вертикальное разрешение H , горизонтальное — как W . Так, полагаем, что

$$c_x = \frac{W}{2}, \quad c_y = \frac{H}{2}$$

Матрица внутренних параметров таким образом превращается в

$$K = \begin{pmatrix} f & 0 & \frac{W}{2} \\ 0 & f & \frac{H}{2} \\ 0 & 0 & 1 \end{pmatrix}, \quad (17)$$

Далее, матрица внешних параметров есть

$$[R \mid t] \in \mathbb{R}^{3 \times 4},$$

где $R \in \mathbb{R}^{3 \times 3}$ — матрица поворота, задающая ориентацию камеры в пространстве, а $t \in \mathbb{R}^3$ — вектор переноса, задающий положение центра камеры в глобальной (мировой) системе координат.

Для удобства представления преобразований используется так называемое однородное представление точек, в котором трехмерная точка $P = (X, Y, Z)^T \in \mathbb{R}^3$ расширяется до вектора $P' = (X, Y, Z, 1)^T$.

Таким образом, проекция трехмерной точки P из глобальных координат в координаты относительно камеры задается выражением:

$$P_c = (X_c, Y_c, Z_c)^T = [R \mid t]P' = RP + t, \quad (18)$$

что соответствует повороту с помощью матрицы R и смещению на вектор t .

Перейдем в нормализованные координаты:

$$(x_n, y_n, 1)^T = \frac{P_c}{Z_c} = \left(\frac{X_c}{Z_c}, \frac{Y_c}{Z_c}, 1 \right)^T \quad (19)$$

Матрица K определяет соотношение между нормализованными координатами (19) и координатами точки на двумерном изображении (иначе говоря, между трехмерными и «пиксельными» координатах):

$$\begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = K \begin{pmatrix} x_n \\ y_n \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{X_c}{Z_c} f_x + \frac{Y_c}{Z_c} f_y + c_x \\ \frac{Y_c}{Z_c} f_y + c_y \\ 1 \end{pmatrix} = \{ \text{в упрощ. модели (17)} \} = \begin{pmatrix} \frac{X_c}{Z_c} f + \frac{W}{2} \\ \frac{Y_c}{Z_c} f + \frac{H}{2} \\ 1 \end{pmatrix} \quad (20)$$

3.8.1 Случай установки с одной камерой

Полагаем $Z_c \neq 0$. Тогда

$$X_c = \frac{u - \frac{W}{2}}{f} Z_c, \quad Y_c = \frac{v - \frac{H}{2}}{f} Z_c \quad (21)$$

Получили, что, зная пиксельные координаты, можно однозначно восстановить трехмерные координаты, зная также глубину Z_c .

На рис. (4) графически представлена используемая модель камеры.




Рис. 4: Простейшая модель камеры-обскуры.

В используемой простейшей модели камеры, без искажений, выполнено (приближенно)

$$\frac{f}{h_i} = \frac{Z_c}{h_c} \text{ и, следовательно, } Z_c = \frac{f}{h_i} h_c \quad (22)$$

где h_i — размер (высота) объекта на изображении, h_c — реальный размер (высота) объекта, f — фокусное расстояние, Z_c — глубина объекта в глобальных координатах относительно камеры.

Вспомним, что MotionBERT предсказывает трехмерную позу (скелетную модель), для которой затем выполняется нормализация. Это преобразование для каждого кадра задается формулой (9). Функцию $norm(t)$, зависящую от номера кадра t , можно интерпретировать как видимый размер позы в данный момент времени (умноженный на константу), притом уже учитывающий пространственную информацию, то есть изменение видимого (двумерного) размера при изменении положения позы в пространстве.

Обозначим, для удобства, $S(t) := norm(t)$.

Так, на основе формулы (22) можно ввести модель, задающую примерную глубину (координату Z_c) точек позы на основании имеющихся данных и предсказаний трехмерной

позы. Пусть h_c задает реальный размер человека (например, сумму «костей» скелетной модели). Тогда с высокой точностью $h_c = \text{const}$. Если f представляется известным, то Z_c находится однозначно. Как было сказано, примерно выполнено $S(t) = C' \cdot h_i(t)$, $C' = \text{const}$. Отсюда построим модели для оценки глубины позы относительно камеры.

$$Z_c(t) = \frac{f}{S(t)} \cdot L, \quad L = \text{const}. \quad \text{Тогда } Z_c(t) = \frac{\lambda}{S(t)}, \quad (23)$$

где $\lambda = \lambda(f)$ — некоторый константный (на всей последовательности кадров) параметр, зависящий от фокусного расстояния f .

Отсюда, а также из (21), имеем следующую примерную формулу для координат в t -й момент времени:

$$(X_c(t), Y_c(t), Z_c(t))^T = \left(\frac{\lambda}{f \cdot S(t)} \left(u - \frac{W}{2} \right), \frac{\lambda}{f \cdot S(t)} \left(v - \frac{H}{2} \right), \frac{\lambda}{S(t)} \right)^T. \quad (24)$$

Очевидно, построенная поза не будет точна, если для всех точек принять глубину равной одному и тому же значению, поэтому положим, что формула (24) задает координаты точки, отвечающей тазу (так как для относительной трехмерной позы, предсказанной MotionBERT, именно таз имеет координаты $(0, 0, 0)^T$).

Тогда если $(X_{rel}, Y_{rel}, Z_{rel})^T$ — координаты некоторой точки относительной позы, предсказанной MotionBERT, то положение данной точки в глобальных координатах, связанных с камерой, будет оцениваться как $(X_{rel} + X_c, Y_{rel} + Y_c, Z_{rel} + Z_c)^T$, где $(X_c, Y_c, Z_c)^T$ находятся согласно (24) для каждого кадра соответственно.

Итого, с учетом (21), для каждой точки реконструированной трехмерной позы ее пиксельные координаты выражаются как

$$\begin{aligned} \tilde{u}(t) &= \frac{X_{rel}(t) + \frac{\lambda}{fS(t)}(u_0(t) - \frac{W}{2})}{Z_{rel}(t) + \frac{\lambda}{S(t)}} f + \frac{W}{2} \\ \tilde{v}(t) &= \frac{Y_{rel}(t) + \frac{\lambda}{fS(t)}(v_0(t) - \frac{H}{2})}{Z_{rel}(t) + \frac{\lambda}{S(t)}} f + \frac{H}{2} \end{aligned}$$

Здесь (u_0, v_0) — пиксельные координаты точки, отвечающей тазу, в момент времени t .

Перегруппируем слагаемые так, чтобы выделить линейную часть с f и свободный член:

$$\begin{aligned} \tilde{u}(t) &= f \left(\frac{X_{rel}(t)}{Z_{rel}(t) + \frac{\lambda}{S(t)}} \right) + \left(\frac{W}{2} + \frac{\frac{\lambda}{S(t)}}{Z_{rel}(t) + \frac{\lambda}{S(t)}} \left(u_0(t) - \frac{W}{2} \right) \right) \\ \tilde{v}(t) &= f \left(\frac{Y_{rel}(t)}{Z_{rel}(t) + \frac{\lambda}{S(t)}} \right) + \left(\frac{H}{2} + \frac{\frac{\lambda}{S(t)}}{Z_{rel}(t) + \frac{\lambda}{S(t)}} \left(v_0(t) - \frac{H}{2} \right) \right) \end{aligned} \quad (25)$$

Введем обозначения:

$$\begin{aligned} a_i(t) &= \frac{X_{rel}(t)}{Z_{rel}(t) + \frac{\lambda}{S(t)}} & \alpha_i(t) &= \frac{W}{2} + \frac{\frac{\lambda}{S(t)}}{Z_{rel}(t) + \frac{\lambda}{S(t)}}(u_0(t) - \frac{W}{2}) \\ b_i(t) &= \frac{Y_{rel}(t)}{Z_{rel}(t) + \frac{\lambda}{S(t)}} & \beta_i(t) &= \frac{H}{2} + \frac{\frac{\lambda}{S(t)}}{Z_{rel}(t) + \frac{\lambda}{S(t)}}(v_0(t) - \frac{H}{2}) \end{aligned} \quad (26)$$

Формулы (25) дают пиксельные координаты точек реконструированной трехмерной позы. При этом уже известны пиксельные координаты (u, v) , обнаруженные на этапе оценки 2D позы. Это позволяет связать параметр λ с фокусным расстоянием f , однозначно восстановив фокусное расстояние по λ . Это можно сделать с помощью минимизации так называемой ошибки репроекции по всевозможным f для данного λ .

Введем ошибку репроекции для некоторого кадра t :

$$E_t(f) = \sum_i ((u_i(t) - a_i(t)f - \alpha_i(t))^2 + (v_i(t) - b_i(t)f - \beta_i(t))^2). \quad (27)$$

Суммирование здесь берется по всем точкам i скелета (за исключением, быть может, таза, ведь для него ошибка репроекции в рамках построенной модели будет нулевой). Формат двумерной позы с этапа 2D детекции считается соответствующим формату трехмерной позы.

Полная ошибка репроекции на всем видео есть соответственно $E(f) = \sum_t E_t(f)$. Сумма берется по всем кадрам.

Формулу (27) можно переписать в виде квадратного трехчлена.

$$\begin{aligned} E_t(f) &= A(t)f^2 - 2B(t)f + C(t), \text{ где} \\ A(t) &= \sum_i (a_i^2(t) + b_i^2(t)), \quad B(t) = \sum_i ((u_i(t) - \alpha_i(t))a_i(t) + (v_i(t) - \beta_i(t))b_i(t)). \end{aligned} \quad (28)$$

Следовательно, и полная ошибка $E(f)$ также представима в виде квадратного трехчлена:

$$E(f) = Af^2 - 2Bf + C, \text{ где } A = \sum_t A(t), \quad B = \sum_t B(t), \quad (29)$$

где $A(t), B(t)$ находятся из (28), а C — свободный член. Так, очевидна формула для нахождения точки минимума:

$$\arg \min_f E(f) = \frac{B}{A}, \quad (30)$$

где коэффициенты A, B вычисляются по известным данным при фиксированном λ согласно (26)–(29).

Итак, по параметру λ была получена оценка фокусного расстояния f .

Рассмотрим вопрос о том, какая пара $(\lambda, f(\lambda))$ соответствует наиболее правдоподобной трехмерной реконструкции. Заметим тот факт, что в данной работе речь идет о видео, на которых запечатлена в том числе походка людей в кадре. Также заметим, что если фокусное расстояние выбрано неверно слишком большим, то, согласно (23), глубина будет изменяться с течением времени неестественно сильно. Наоборот, если фокусное расстояние выбрано неверно слишком малым, то, из той же формулы, глубина будет изменяться неестественно слабо. На практике этот эффект приведет к тому, что на реконструкции, полученной при чрезмерно высокой или чрезмерно низкой оценке f , стопа во время фазы опоры [42] будет как бы «проскальзывать» по земле, в то время как лишь при оценке, приближенной к реальности, координата стопы будет почти неизменна в течение фазы опоры.

Отсюда вытекают задачи: идентифицировать моменты времени, в которые человек осуществляет ходьбу (а не иное действие); далее выделить в эти моменты времени фазы опоры и маха; наконец, оптимизировать функцию ошибки, составленную в том числе на основе информации о кадрах, соответствующих началам и концам фаз маха.

Задача о выделении кадров, на которых запечатлена походка (с достаточно высокой уверенностью обнаружения 3D точек с помощью MotionBERT), решается путем введения метрики качества. MotionBERT дает представление о примерной относительной позе человека. Стало быть, на основе количественных характеристик относительной позы можно составить метрику, учитывающую, например, асимметрию для левой и правой ноги во время ходьбы, скорости стоп и иные характеристики, максимизирующие метрику именно во время ходьбы.

В данной работе реализована метрика — обозначим ее $sc(t)$ — учитывающая разницу углов в коленях (для трехмерной относительной позы) правой и левой ног, разницу координат, отвечающих за высоту левой и правой стоп над землей, скорость стоп, их ускорение, скорости колен. Данные количественные признаки далее нормализуются и суммируются с некоторыми фиксированными весами. Для уменьшения шума дополнительно применяется сглаживание с помощью гауссовского фильтра. По метрике выделяются временные интервалы, для которых

$$sc(t) > d, \text{ где } d — \text{некоторый порог, подобранный эмпирически.} \quad (31)$$

Под скоростью и ускорением стоит понимать дискретные производные по времени.

Для разделения фаз опоры и маха для выбранных кадров используется вероятностная кластеризация признаков отдельно для левой и правой ног. Для сформированных на предыдущем этапе векторов признаков (количественных характеристик относительной позы для каждого кадра) применяется модель смеси гауссовских распределений (Gaussian Mixture Model, GMM) [7] с двумя компонентами, что соответствует предположению о наличии двух основных состояний движения: фазы опоры и фазы маха. Кластеризация выполняется независимо для левой и правой ноги. Заметить, что мы используем данную модель как вероятностный классификатор.

После кластеризации требуется определить, какой кластер отвечает фазе маха и какой — фазе опоры. Для этого вычисляется метрика, определяемая как среднее значение суммы квадратов скорости стопы и скорости колена по всем кадрам. Кластер с бóльшим значением метрики идентифицируется как отвечающий фазам маха.

Для сглаживания полученных вероятностей и предотвращения вырождения оценок применяется температурное масштабирование [28] и ограничение вероятностей снизу и сверху на малые положительные числа $0 < \varepsilon_1, \varepsilon_2 \ll 1$ с учетом того, что сумма вероятностей равна единице.

Формализуем полученный результат. Модель смеси гауссовских распределений (с учетом описанной выше постобработки) дает оценки вероятностей принадлежности кадров кластерам

$$p_k(t) = \mathbb{P}(z_t = k \mid x_t), \quad k \in \{0, 1\}, \quad z_t \in \{0, 1\}.$$

Здесь $z_t \in \{0, 1\}$ — скрытая переменная, задающая принадлежность t к одному из двух кластеров, x_t — наблюдаемый вектор признаков, k идентифицирует кластеры (каждый кластер как либо отвечающий фазам опоры, либо фазам маха). Без ограничения общности, в рамках реализации принято соглашение: кластер опоры есть $k = 0$, кластер маха есть $k = 1$.

В рамках процесса, описываемого формулой (31), выделяются последовательные (непрерывные) временные интервалы. Для учета временной согласованности фаз ходьбы (и, как следствие, устранения шума) на каждом таком интервале дополнительно вводится марковская цепь с двумя возможными состояниями.

Предполагается, что последовательность $\{z_t\}$ обладает свойством:

$$\mathbb{P}(z_t \mid z_{1:t-1}) := \mathbb{P}(z_t \mid z_{t-1}, z_{t-2}, \dots, z_1) = \mathbb{P}(z_t \mid z_{t-1}).$$

Переходы между состояниями задаются матрицей вероятностей перехода A с элементами a_{ij} :

$$a_{ij} = \mathbb{P}(z_t = j \mid z_{t-1} = i), \quad i, j \in \{0, 1\}.$$

В рамках данной работы используется, в частности, следующая фиксированная матрица переходов:

$$A = \begin{pmatrix} 0.95 & 0.05 \\ 0.08 & 0.92 \end{pmatrix}.$$

Для видео с кадровой частотой 30 кадров/с она отражает предположение о примерной длительности периода цикла ходьбы в секундах и длительности фаз опоры и маха в процентном отношении от всего периода цикла ходьбы для человека [42].

Оценки вероятностей $p_k(t)$ и построенная модель используются для восстановления наиболее правдоподобной в смысле оптимизации некоторого функционала последовательности скрытых состояний $\{z_t\}_{t=1}^{\tilde{T}}$ ($\tilde{T}$ — число кадров на выбранном интервале).

Задача нахождения наиболее согласованной последовательности состояний, таким образом, может быть сформулирована следующим образом:

$$\hat{z}_{1:\tilde{T}} = \arg \max_{z_{1:\tilde{T}}} W(z_{1:\tilde{T}}), \text{ где } W(z_{1:\tilde{T}}) = \prod_{t=1}^{\tilde{T}} p_{z_t}(t) \prod_{t=2}^{\tilde{T}} a_{z_{t-1}z_t}.$$

Эквивалентно:

$$\hat{z}_{1:\tilde{T}} = \arg \max_{z_{1:\tilde{T}}} \left(\log W(z_{1:\tilde{T}}) \right) = \arg \max_{z_{1:\tilde{T}}} \left(\sum_{t=1}^{\tilde{T}} \log p_{z_t}(t) + \sum_{t=2}^{\tilde{T}} \log a_{z_{t-1}z_t} \right). \quad (32)$$

Здесь под $z_{1:\tilde{T}}$, как и ранее, понимается последовательность состояний $\{z_t\}_{t=1}^{\tilde{T}}$, $z_t \in \{0, 1\}$. Всего таких объектов $2^{\tilde{T}}$.

Задача (32) может быть сведена к задаче динамического программирования.

Пусть $V_t(j)$ обозначает максимальное значение функционала W для всех последовательностей длины t , заканчивающихся в состоянии j :

$$V_t(j) = \max_{\substack{z_{1:t} \\ z_t=j}} W(z_{1:t}).$$

Тогда, в силу принципа оптимальности Беллмана:

$$V_t(j) = \max_{i \in \{0,1\}} [V_{t-1}(i) a_{ij} p_j(t)] .$$

Эквивалентно:

$$\log V_t(j) = \max_{i \in \{0,1\}} [\log V_{t-1}(i) + \log a_{ij} + \log p_j(t)] .$$

Данное соотношение представляет собой уравнение Беллмана. Решение задачи (32) осуществляется с использованием алгоритма Витерби [12].

На рис. 5 и рис. 6 графически представлен результат применения кластеризации (с постобработкой) для получения оценок вероятностей принадлежности моментов времени фазам маха или опоры и последующего применения описанного метода устранения шумов. Напомним, что в данной работе число 0 соответствует фазе опоры (1 — фазе маха).




Рис. 5: Результат сегментации фаз походки на видео 1. (a) Вероятности фазы маха для правой ноги; (b) Вероятности фазы маха для левой ноги; (c) Восстановленная последовательность состояний для правой ноги; (d) Восстановленная последовательность состояний для левой ноги.




Рис. 6: Результат сегментации фаз походки на видео 2. (a) Вероятности фазы маха для правой ноги; (b) Вероятности фазы маха для левой ноги; (c) Восстановленная последовательность состояний для правой ноги; (d) Восстановленная последовательность состояний для левой ноги.

Далее в рамках задачи оценки фокусного расстояния вводится метрика, основанная на предположении о неподвижности стопы во время фазы опоры. В частности, в корректно восстановленной системе координат положение стопы в течение интервала контакта (опоры) практически не должно изменяться.

Для каждого значения параметра λ выполняется подбор f (согласно (26)–(30)) и реконструкция трехмерных координат ключевых точек в мировой системе координат. Для этого для точки, отвечающей тазу, восстанавливаются мировые относительно камеры координаты (согласно (23)–(24)). Далее к координатам каждой точки относительной позы (полученной с помощью MotionBERT) прибавляется полученный в результате предыдущего шага вектор.

Тогда функция потерь $J(\cdot)$, зависящая от параметра λ , определяется как сумма

отклонений положения стопы внутри каждого интервала контакта:

$$J_L(\lambda) = \sum_{k=1}^K \left(\|\mathbf{X}_\lambda(t_e^k) - \mathbf{X}_\lambda(t_s^k)\|^2 + \|\mathbf{X}_\lambda(t_m^k) - \mathbf{X}_\lambda(t_s^k)\|^2 + \|\mathbf{X}_\lambda(t_e^k) - \mathbf{X}_\lambda(t_m^k)\|^2 \right),$$

где сумма по k обозначает сумму по всем фазам опоры левой ноги, t_s^k — начало k -й фазы опоры (кадр), t_e^k — ее конец, $t_m^k = \lfloor (t_s^k + t_e^k)/2 \rfloor$ — промежуточный момент времени внутри интервала контакта, $\mathbf{X}_\lambda(t)$ обозначает координаты левой стопы в момент времени t , восстановленные с параметром λ .

Совершенно аналогично определяется функция ошибки для правой ноги: $J_R(\lambda)$. В результате функция потерь есть:

$$J(\lambda) = J_L(\lambda) + J_R(\lambda).$$

Искомый параметр λ выбирается как решение задачи оптимизации:

$$\lambda^* = \arg \min_{\lambda} J(\lambda).$$

Анализ графиков в рамках экспериментов показал, что у $J(\lambda)$ явный единственный минимум в случае всех видео из датасета. Допустим перебор параметра по достаточно плотной сетке.

Наконец, оценка истинного фокального расстояния и искомая поза в мировых координатах относительно камеры получаются в результате восстановления ее с параметром λ^* .

3.8.2 Случай установки с несколькими камерами

В случае двух (и более) камер восстановление трехмерной позы в мировых координатах может осуществляться по соответствующим двумерным ключевым точкам на изображениях с камер (в данной работе они получаются с помощью модели RTMPose). Для регуляризации и устранения неоднозначности далее рассмотрим метод, использующий априорные знания в виде трехмерной позы, полученной моделью MotionBERT (достаточно взять относительную трехмерную позу, полученную для лишь одной из камер).

Пусть для двух камер известны пиксельные координаты наборов соответствующих двумерных ключевых точек:

$$x_i^{(1)}(t), x_i^{(2)}(t) \in \mathbb{R}^2,$$

где $i = 1, \dots, M$ — индекс ключевой точки, а $t = 1, \dots, T$ — индекс кадра. В данном разделе также считаем, что формат двумерных ключевых точек совпадает с форматом трехмерных (в программной реализации взят формат Human3.6M (17 точек) для обоих вариантов).

Также пусть известна относительная трехмерная поза, полученная MotionBERT:

$$\tilde{X}_i(t) \in \mathbb{R}^3 — \text{трехмерные координаты } i\text{-й точки на } t\text{-м кадре.}$$

Основная идея рассматриваемого метода заключается в следующем: по соответствующим двумерным точкам оценивается взаимная геометрия камер, после чего выполняется триангуляция [15] трехмерных точек. Далее полученная реконструкция сопоставляется с априорной позой MotionBERT, и выполняется подбор параметров камер, минимизирующих ошибку между триангулированной и априорной позами. Интуитивно, данный метод дает наиболее «правдоподобную» реконструкцию в смысле соответствия триангулированной позы априорной.

Используем модель камеры, введенную в начале раздела. Пусть K_1, K_2 — матрицы, задающие внутренние параметры первой и второй камер соответственно. K_1, K_2 принимаются удовлетворяющими упрощенной модели (17). $[R_1 \mid t_1], [R_2 \mid t_2]$ — матрицы, задающие внешние параметры первой и второй камер соответственно.

Пусть есть трехмерная точка $(X, Y, Z)^T \in R^3$ и соответствующие ей точки $(u_1, v_1), (u_2, v_2) \in R^2$ на двумерных изображениях, получаемых первой и второй камерами. Соответственно обозначим их однородные представления:

$$\tilde{X} = (X, Y, Z, 1)^T, \quad x_1 = (u_1, v_1, 1)^T, \quad x_2 = (u_2, v_2, 1)^T.$$

Введем для двух камер так называемые матрицы проекции:

$$P_1 = K_1[R_1 \mid t_1], \quad P_2 = K_2[R_2 \mid t_2].$$

Тогда из (18)–(20) имеем:

$$\lambda_j x_j = P_j \tilde{X}, \text{ или } x_j \sim K_j(R_j(X, Y, Z)^T + t_j), \quad j = 1, 2.$$

Здесь λ_j — коэффициент, отвечающий глубине точки в мировых координатах относительно j -й камеры, $\sim$ означает равенство с точностью до ненулевого множителя.

Из (20) имеем:

$$\hat{x}_j = K_j^{-1}x_j, \quad j = 1, 2 \implies \hat{x}_j \sim R_j(X, Y, Z)^T + t_j, \quad j = 1, 2. \quad (33)$$

Выразим положение точки $\bar{X} = (X, Y, Z)^T$ в мировой относительно второй камеры $\bar{X}_c^2 = (X_c^2, Y_c^2, Z_c^2)^T$ системе координат через ее координаты $\bar{X}_c^1 = (X_c^1, Y_c^1, Z_c^1)^T$ относительно первой.

$$\begin{aligned} \bar{X}_c^1 &= R_1 \bar{X} + t_1, \quad \bar{X}_c^2 = R_2 \bar{X} + t_2 \implies R_1^T \bar{X}_c^1 = \bar{X} + R_1^T t_1 \implies \bar{X} = R_1^T \bar{X}_c^1 - R_1^T t_1 \\ &\implies \bar{X}_c^2 = R_2(R_1^T \bar{X}_c^1 - R_1^T t_1) + t_2 = R_2 R_1^T \bar{X}_c^1 + (t_2 - R_2 R_1^T t_1) \end{aligned}$$

Пусть $R := R_2 R_1^T$ и $t := t_2 - R t_1$. Тогда

$$\bar{X}_c^2 = R \bar{X}_c^1 + t$$

Итак, некоторая трехмерная точка задает две трехмерные точки $\hat{x}_1, \hat{x}_2 \in \mathbb{R}^3$ в относительных первой и второй камеры системах координат согласно (33). В мировой системе координат относительно данной камеры центр этой камеры имеет координаты $(0, 0, 0)^T$. Так, векторы $\hat{x}_1, \hat{x}_2$ задают лучи, проходящие через центры камер и точку в пространстве. Геометрически три вектора $\hat{x}_1, \hat{x}_2, t$ лежат в одной плоскости (эпиполярной плоскости). Следовательно, их смешанное произведение равно нулю:

$$\hat{x}_2^T (t \times (R \hat{x}_1)) = 0.$$

Введем матричное представление векторного произведения. Для любого вектора $t = (t_1, t_2, t_3)^T$ определим матрицу $[t]_\times$ вида:

$$[t]_\times = \begin{pmatrix} 0 & -t_3 & t_2 \\ t_3 & 0 & -t_1 \\ -t_2 & t_1 & 0 \end{pmatrix}.$$

Тогда для любого вектора $a \in \mathbb{R}^3$ выполняется равенство $t \times a = [t]_\times a$.

Так, получаем

$$t \times (R \hat{x}_1) = [t]_\times R \hat{x}_1.$$

Тогда справедлива формула:

$$\hat{x}_2^T [t]_\times R \hat{x}_1 = 0. \quad (34)$$

Определим так называемую фундаментальную матрицу:

$$F = K_2^{-T}[t]_{\times} R K_1^{-1}. \quad (35)$$

Возвращаясь к пиксельным координатам x_1, x_2 , используя (33), получаем так называемое эпиполярное ограничение:

$$x_1^T F x_2 = 0.$$

Фундаментальная матрица F оценивается из набора соответствий двумерных ключевых точек $(x_i^{(1)}(t), x_i^{(2)}(t))$. Предварительная синхронизация позволяет сопоставить все точки, полученные по видео с первой камеры, всем точкам, полученным по видео со второй камеры. Так, для видео с T кадрами (с учетом урезания при синхронизации), где на каждом кадре доступно M ключевых точек, во множестве соответствий есть $T \cdot M$ элементов.

Оценка F производится с использованием метода RANSAC [11] для исключения точек-выбросов, наличие которых обусловлено погрешностью на этапе 2D-детекции.

Так, фиксируется число итераций алгоритма. На каждой итерации случайным образом выбирается набор из 8 соответствий (из всех $T \cdot M$ соответствий), и по нему с помощью восьмиточечного алгоритма [16] оценивается фундаментальная матрица. Далее с помощью метрики расстояния [33] отбрасываются точки, являющиеся выбросами (метрика расстояния больше заданного порога). Подсчитывается количество точек, являющихся не-выбросами (inliers). На множестве всех итераций выделяется наилучшая по наибольшему количеству точек, не являющихся выбросами. Множество соответствующих точек запоминается.

Формально, для каждой итерации k определяется множество не-выбросов:

$$\mathcal{I}_k = \{i \mid d(x_i^{(1)}, x_i^{(2)}, F_k) < \tau\},$$

где F_k — фундаментальная матрица, оцененная на k -й итерации, τ — заданный порог.

Критерием качества k -й итерации является размер множества не-выбросов $|\mathcal{I}_k|$. Оптимальная итерация выбирается как $k^* = \arg \max_k |\mathcal{I}_k|$. Множество I^* определяется как I_{k^*} .

После завершения RANSAC выполняется повторная оценка фундаментальной матрицы с использованием всех не-выбросов k^* -й итерации с помощью восьмиточечного алгоритма. Получается матрица F^* .

В дальнейшем полученную наилучшую оценку фундаментальной матрицы F^* будем обозначать как $\hat{F}$.

После оценки F выполняется оценка f_1, f_2, R, t .

Для начала предположим, что f_1, f_2 фиксированы и являются некоторыми положительными числами. Тогда матрицы K_1, K_2 известны:

$$K_1 = \begin{pmatrix} f_1 & 0 & \frac{W_1}{2} \\ 0 & f_1 & \frac{H_1}{2} \\ 0 & 0 & 1 \end{pmatrix}, \quad K_2 = \begin{pmatrix} f_2 & 0 & \frac{W_2}{2} \\ 0 & f_2 & \frac{H_2}{2} \\ 0 & 0 & 1 \end{pmatrix}.$$

Введем матрицу $\hat{E}$:

$$\hat{E} = K_2^T \hat{F} K_1$$

Заметим, что (34), (35), при верно выбранных фокальных расстояниях выполнено:

$$\hat{E} \approx [t]_{\times} R.$$

Разница с (34) в данном случае в том, что $\hat{E}$ будет лишь оценкой E , полученной на основе оценки F для выбранных фиксированных фокальных расстояний f_1, f_2 .

Полученная оценка E позволяет получить оценку $\hat{R}$ на матрицу вращения R и оценку $\hat{t}$ на вектор смещения t для восстановления положения камер.

Для $\hat{E}$ далее будет выполняться сингулярное разложение.

Матрица $[\hat{t}]_{\times}$ для любого $\hat{t}$ является кососимметричной и соответствует операции векторного произведения $\hat{t} \times x$. Так, лишь векторы, параллельные $\hat{t}$, будут входить в ее ядро. Ранг данной матрицы равен двум.

Далее, существует ортонормированная система координат, в которой $\hat{t} = (0, 0, \|\hat{t}\|)^T$. Тогда матрица принимает вид

$$[\hat{t}]_{\times} = \begin{pmatrix} 0 & -\|\hat{t}\| & 0 \\ \|\hat{t}\| & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix},$$

что приводит к сингулярным значениям $(\|\hat{t}\|, \|\hat{t}\|, 0)$ для этой матрицы. Отсюда, для любой матрицы вращения $\hat{R}$ сингулярные числа $[\hat{t}]_{\times} \hat{R}$ есть в точности $(\sigma, \sigma, 0)$, где $\sigma = \|\hat{t}\|$.

Вернемся ненадолго к свойствам реальной существенной матрицы E . Из рассмотренного выше сингулярное разложение E будет давать:

$$E = U \Sigma V^T, \quad \Sigma = \text{diag}(\sigma, \sigma, 0).$$

Введем матрицы $\tilde{E}$ и W .

$$\tilde{E} := \frac{1}{\sigma} E = U \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} V^T, \quad W = \begin{pmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad (36)$$

Для матриц $\tilde{E}$ с сингулярными значениями $(1, 1, 0)$, то есть любой приведенной существенной матрицы, разложенной в виде (36), если принять матрицу внешних параметров первой камеры $[R_1 \mid t_1] = [I \mid 0]$, для второй камеры матрица внешних параметров $[R_2 \mid t_2]$ будет иметь один из четырех видов [15, р. 259]:

$$[UWV^T \mid u^3], \quad [UWV^T \mid -u^3], \quad [UW^TV^T \mid u^3], \quad [UW^TV^T \mid -u^3], \quad (37)$$

где u^3 есть последний столбец матрицы U .

Из этих четырех решений лишь одну будет таким, что любая реконструированная точка будет лежать перед двумя камерами, а не позади них (то есть глубина точки в мировых относительно как первой, так и второй камеры координатах будет положительна лишь для одного решения).

На основании вышесказанного, при поиске фокальных расстояний f_1, f_2 наилучший кандидат $[R \mid t]$ будет отбираться как тот, при котором число точек, лежащих перед камерами после триангуляции, максимально.

Наконец, обозначим $[\hat{R} \mid \hat{t}]$ ту оценку на матрицу внешних параметров, которая была получена на основании (36), (37). Матрица внешних параметров первой камеры, напомним, принимается $[I \mid 0]$.

Для каждой пары соответствующих точек (x_1, x_2) восстанавливается трехмерная (здесь — в однородных координатах вида $(X, Y, Z, 1)$) точка $\hat{X}$ с помощью триангуляции.

Матрицы внешних параметров камер:

$$P_1 = K_1[I \mid 0], \quad P_2 = K_2[R \mid t].$$

Условие проекции точек записывается как:

$$x_1 \sim P_1 \hat{X}, \quad x_2 \sim P_2 \hat{X},$$

что эквивалентно [15] однородной системе:

$$A\hat{X} = 0,$$

где матрица $A \in \mathbb{R}^{4 \times 4}$ задается как:

$$A = \begin{pmatrix} u_1 P_1^{(3)} - P_1^{(1)} \\ v_1 P_1^{(3)} - P_1^{(2)} \\ u_2 P_2^{(3)} - P_2^{(1)} \\ v_2 P_2^{(3)} - P_2^{(2)} \end{pmatrix},$$

а (u_i, v_i) — координаты точки на изображении, $P^{(j)}$ — j -я строка матрицы P .

Решение $\tilde{X}$ находится как сингулярный вектор, соответствующий наименьшему сингулярному значению матрицы A :

$$\tilde{X} = \arg \min_{\|\hat{X}\|=1} \|A\hat{X}\|.$$

Далее выполняется переход к однородным координатам:

$$\hat{X} = \frac{1}{X_4} \tilde{X} = (X, Y, Z, 1)^T,$$

где X_4 — последняя компонента полученного решения $\tilde{X}$. $(X, Y, Z)^T$, соответственно, будет координатным вектором триангулированной точки.

Данный процесс восстанавливает трехмерную структуру с точностью до некоторого коэффициента масштаба.

После триангуляции всех точек позы для каждого кадра получается реконструированная трехмерная позы, которую можно сравнивать некоторым образом с априорной, полученной с помощью MotionBERT. Сравнение производится по метрике, заданной (12), с учетом коэффициента масштаба s . В терминах раздела 3.7.1 коэффициент масштаба задается следующим образом: в сингулярном разложении (13) возникает матрица сингулярных значений Σ . Тогда формула для коэффициента масштаба есть [35]:

$$s = \frac{tr(\Sigma)}{\|A_0\|_F^2}$$

Интуитивно данное сравнение можно понимать, как «естественность» реконструкции позы.

В реализации сделан выбор в пользу сравнения с помощью прокрустова преобразования всей реконструированной траектории со всей априорной сразу. Для этого предварительно для реконструированной траектории — которая восстанавливается в мировых координатах — получается относительная траектория путем вычитания координаты таза из координат всех точек реконструированной позы для каждого кадра.

Полученная ошибка, вычисленная согласно (12), и будет являться ошибкой реконструкции.

Итак, для каждой пары фокальных расстояний (f_1, f_2) получили суммарную ошибку

$$L(f_1, f_2). \quad (38)$$

Функция ошибки (38) не имеет простого аналитического выражения. Введем дополнительно параметризацию:

$$f_1(z_1) = e^{z_1}, \quad f_2(z_2) = e^{z_2}. \quad (39)$$

Тогда задача поиска оптимальной пары фокальных расстояний сводится к задаче безусловной оптимизации.

Для минимизации функции ошибки в рамках реализации используется метод Нелдера–Мида [26]. Задача минимизации:

$$\min_{z \in \mathbb{R}^2} L(e^{z_1}, e^{z_2})$$

Метод Нелдера–Мида требует начальный симплекс. Для этого строится начальное приближение [36], записываемое в общем случае как $z_0 \in \mathbb{R}^n$:

$$z^{(0)} = z_0,$$

$$z^{(k)} = z_0 + \delta_k e_k, \quad k = 1, \dots, n,$$

где

$$\delta_k = \begin{cases} \varepsilon_1 \cdot z_{0,k}, & \text{если } z_{0,k} \neq 0, \\ \varepsilon_2, & \text{иначе,} \end{cases}$$

$\varepsilon_1, \varepsilon_2$ — некоторые малые числа, $z_{0,k}$ — k -я компонента начального приближения, e_k — вектор вида $(0, \dots, 0, 1, 0, \dots, 0)^T$ с единицей в k -й позиции. В рамках рассматриваемой в разделе задачи $n = 2$.

Непосредственно точка z_0 в рамках работы находится перебором по сетке пар вида (f, f) с выбором наилучшей по критерию (38), после чего применяется логарифмическое преобразование, описанное формулой (39).

Решение, полученное в задаче, будет оценкой фокальных расстояний первой и второй камеры (после преобразования (39)).




Рис. 7: Примеры визуализации ландшафта функции потерь для двух различных пар видео. Красной точкой выделен минимум. Верхний график представляет ошибку для пары видео с невырожденным расположением двух камер и субъекта друг относительно друга, нижний — ошибку для пары видео, для которой субъект находится вблизи отрезка в пространстве, соединяющего центры камер. Значения функции потерь усечены сверху.

4 Эксперименты

В данном разделе представлены метрики, позволяющие оценить качество метода оценки трехмерной позы в условиях отсутствия эталонных (ground truth) данных. Основная цель — численно проанализировать влияние различных элементов пайплайна на улучшение точности и стабильности предсказаний.

Для экспериментов использовались данные, описанные в разделе 3.2. Количество видео в датасете — 11 штук, из которых 2 пары видео записаны в конфигурации с двумя камерами.

В рамках данного раздела нумерация видео везде совпадает с той, что приведена в таблице 2: одно и то же видео далее сохраняет свой номер.

4.1 Оценка 2D детекции

Сравним уверенность 2D детекции для всех видео. Выберем лишь точки, которые далее используются при переводе из формата двумерной позы `Nalpe26` в формат `Human3.6M`. По каждому видео приведем данные как для всего видео, так и для той половины видео, где человек находится ближе к камере. Результаты приведены в таблице 2 и отражают уверенность в детекции именно пациента (главная траектория уже выделена).

RTMPose демонстрирует высокую уверенность (>0.7) в подавляющем большинстве кадров. При этом наблюдается вариативность качества между видео, обусловленная ракурсом съемки: так, пары видео 2–3 и 4–5, записанные в конфигурации с двумя камерами, показывают различия в уровне уверенности внутри пары. Визуальный анализ результатов показал отсутствие систематических ошибок, таких как ошибки идентификации левой и правой сторон тела и слияние двух ног в одну в рамках позы.

При более строгих порогах ($\text{conf} > 0.8$ и выше) доля кадров с соответствующей уверенностью снижается, однако для области «ближе к камере» она в большинстве случаев составляет более 50%. В целом, уверенность выше, когда человек ближе к камере. Это, в частности, оправдывает применение описанного в разделе 3.7 метода слияния, при котором в мультикамерной конфигурации предпочтение в любой момент времени отдается предсказанию на основе тех кадров, где человек ближе к камере (чем точнее 2D детекция, тем, при прочих равных, точнее результаты методов на дальнейших этапах).

Таблица 2: Уверенность в 2D детекции.

Номер видео	Область видео	Всего кадров	% кадров с $\text{conf} > 0.7$	% кадров с $\text{conf} > 0.75$	% кадров с $\text{conf} > 0.8$	% кадров с $\text{conf} > 0.85$
1	Все кадры	2245	100.00%	92.78%	28.33%	0.09%
1	Ближе к камере	1122	100.00%	99.64%	56.24%	0.18%
2	Все кадры	520	91.54%	51.15%	33.08%	0.00%
2	Ближе к камере	260	100.00%	94.62%	66.15%	0.00%
3	Все кадры	586	100.00%	96.08%	64.85%	31.06%
3	Ближе к камере	293	100.00%	100.00%	99.66%	60.75%
4	Все кадры	313	100.00%	93.93%	40.26%	0.00%
4	Ближе к камере	156	100.00%	100.00%	57.69%	0.00%
5	Все кадры	337	100.00%	100.00%	51.63%	11.57%
5	Ближе к камере	169	100.00%	100.00%	71.60%	22.49%
6	Все кадры	420	95.95%	65.71%	25.95%	0.24%
6	Ближе к камере	210	93.81%	88.10%	51.90%	0.48%
7	Все кадры	315	100.00%	95.87%	52.38%	3.17%
7	Ближе к камере	158	100.00%	98.10%	78.48%	6.33%
8	Все кадры	342	100.00%	86.55%	38.89%	0.88%
8	Ближе к камере	171	100.00%	100.00%	71.93%	1.75%
9	Все кадры	299	100.00%	97.66%	48.49%	0.67%
9	Ближе к камере	150	100.00%	97.33%	88.00%	1.33%
10	Все кадры	382	100.00%	90.84%	19.63%	0.00%
10	Ближе к камере	191	100.00%	98.95%	31.94%	0.00%
11	Все кадры	422	100.00%	90.05%	63.51%	3.32%
11	Ближе к камере	211	100.00%	100.00%	97.16%	6.16%

Примечание: Значение conf (уверенность) — среднее значение уверенности в детекции по всем выбранным ключевым точкам в кадре. Процент означает долю кадров (в %), для которых средний conf превышает указанный порог.

4.2 Оценка трекинга и выбора траектории

Для каждого из 11 видео вычислена метрика важности траектории (раздел 3.4) для всех обнаруженных траекторий. Результаты приведены на рис. 8.




Рис. 8: Метрика важности траектории.

Главная траектория была выделена верно автоматически во всех случаях.

Для оценки работы выбранного метода трекинга на датасете было проведено сравнение количества кадров, на которых пациент был обнаружен, с общим их числом. На всех 11 видео пациент был обнаружен на всех кадрах без исключения.

4.3 Оценка лифтинга, слияния и синхронизации. Примеры

В этом подразделе оценим влияние ансамблирования на предсказание позы. Для этого возьмем комбинацию предсказаний с различными весами (7):

- 1) $w_1 = 1, w_2 = w_3 = 0$ (без ансамблирования)
- 2) $w_1 = w_2 = w_3 = \frac{1}{3}$ (одинаковые веса)
- 3) с весами как в утв. из раздела 3.5 (динамически изменяющиеся веса)

Введем метрики:

$$\text{RMSV} = \sqrt{\frac{1}{17(T-1)} \sum_{t=2}^T \sum_{i=1}^{17} \left\| (\tilde{P}_t)_i - (\tilde{P}_{t-1})_i \right\|^2} \quad (40)$$

где T – число кадров, 17 – число ключевых точек,

$\tilde{P}_t \in \mathbb{R}^{17 \times 3}$ – трехмерная поза в кадре t после нормализации (9) с однородными весами (т.е.

$\tilde{w} = (\frac{1}{n}, \dots, \frac{1}{n})$),

$(\tilde{P}_t)_i \in \mathbb{R}^3$ – i -я строка матрицы $\tilde{P}_t$, т.е. трехмерные координаты точки i в кадре t ,

$\| \cdot \|$ – евклидова норма.

Далее, работая в обозначениях раздела 3.6, введем метрику AV (average variance) наподобие функционала $J(\tilde{w})$ (11) в точке $(\frac{1}{n}, \dots, \frac{1}{n})$. Возьмем вектор основных расстояний точно так же, как в (8), за тем лишь исключением, что вместо позы P_t теперь используем $\tilde{P}_t$. Так, $d(t; i, j)$ – это уже нормализованные расстояния, т.к. взяты относительно позы $\tilde{P}_t$ вместо P_t .

Введем среднюю дисперсию AV на основе формул (10), (11):

$$\text{AV} = \sum_{k=1}^n \text{Var}_t(d(t; i_k, j_k)) \quad (41)$$

Метрика RMSV (40) – среднее квадратическое евклидовых расстояний между одними и теми же точками в соседних кадрах. Эта метрика покажет, насколько сильно изменяется позиция точки между кадрами. Большие значения будут означать меньшую плавность.

Метрика AV (41) – средняя дисперсия длин некоторых расстояний между точками. Т.к. длины костей не изменяются с течением времени, то ожидается, что чем точнее предсказание, тем меньше значения AV.

Результаты вычисления метрики при отсутствии ансамблирования, одинаковых и динамически изменяющихся весах представлены в таблице 3.

Эксперименты показали, что метрика RMSV на всех видео максимальна при использовании динамически изменяющихся весов. Худшие результаты наблюдаются при полном отсутствии ансамблирования.

Таблица 3: Плавность предсказаний при ансамблировании.

Номер видео	RMSV (без анс.)	RMSV (одинак. веса)	RMSV (динамич.)	AV (без анс.)	AV (одинак. веса)	AV (динамич.)
1	0.01478	0.01163	0.01017	0.02438	0.02110	0.02164
2	0.03222	0.02878	0.02737	0.01888	0.01319	0.01237
3	0.04245	0.03685	0.03567	0.02218	0.01474	0.01497
4	0.07002	0.04108	0.03587	0.07882	0.03138	0.02362
5	0.04073	0.03504	0.03070	0.02694	0.02014	0.01944
6	0.02830	0.02531	0.02409	0.02705	0.02144	0.02153
7	0.03897	0.04506	0.02356	0.12399	0.16994	0.15756
8	0.09007	0.04218	0.02647	0.19841	0.07011	0.06436
9	0.03336	0.03745	0.02990	0.03976	0.04183	0.03876
10	0.07009	0.04154	0.03449	0.08065	0.02886	0.02250
11	0.06221	0.04055	0.03571	0.07940	0.04367	0.04587

Значения метрики AV менее последовательны. Можно заметить, однако, что на большинстве видео есть существенный разрыв между значениями AV при отсутствии ансамблирования и значениями AV при двух других вариантах. При этом разрыв между двумя другими вариантами – при использовании предсказаний с одинаковыми весами и с динамически изменяющимися весами – уже меньше, а при использовании динамически изменяющихся весов минимум метрики принимается в наибольшем числе случаев (в сравнении с остальными вариантами).

Данные из таблицы 3, а также визуальный анализ показывают, что наибольшая плавность и временная связность предсказаний достигаются в случае весов, зависящих от времени.

Теперь приведем данные, позволяющие оценить эффект слияния в мультикамерной конфигурации. Пары видео, записанные в мультикамерной конфигурации: 2-3 и 4-5. Обозначим предсказания, полученные слиянием видео 2 и 3, как «2+3», а 4 и 5 – «4+5».

Пусть известно, что человек на видео 1 движется по направлению к камере, а на видео 2 – от камеры. Используем эвристический прием: введем веса так, чтобы слияние было гладким, и одновременно больший вес был бы у позы, соответствующей видео с той камеры,

к которой эта поза ближе. Природа данных позволяет сказать, что изначально поза ближе к камере 2, а далее, начиная с момента вблизи середины видео, поза становится ближе к камере 1.

Введем веса на основе сигмoиды:

$$w_1(t) = \frac{1}{1 + \exp(-k(t - t_0))}$$

$$w_2(t) = 1 - \frac{1}{1 + \exp(-k(t - t_0))}$$

$$t = 1, \dots, l$$

t_0 берется равным $\lfloor l/2 \rfloor$. Константа k определяет скорость изменения веса со временем, в частности, при преодолении отметки в $\lfloor l/2 \rfloor$ кадров. Результирующая поза получается подстановкой этих весов в (16).

Сравним слияние с динамическими ($k > 0$) и константными ($k = 0$) весами, а также оценим влияние на RMSV и AV различных размеров окна в рамках прокрустового преобразования (см. раздел 3.7.1).

Таблица 4: Данные для сравнения.

Видео	Всего кадров	RMSV (динамич.)	AV (динамич.)
2	520	0.02737	0.01237
3	586	0.03567	0.01497
4	313	0.03587	0.02362
5	337	0.03070	0.01944

Таблица 5: Плавность предсказаний при слиянии для различных k .

Видео	Кадры	k	RMSV	AV
2+3	420	0.05	0.03615	0.02327
4+5	237	0.05	0.03819	0.02664

Видео	Кадры	k	RMSV	AV
2+3	420	0.02	0.03489	0.01784
4+5	237	0.02	0.03385	0.01719

Видео	Кадры	k	RMSV	AV
2+3	420	0.01	0.03293	0.01157
4+5	237	0.01	0.03097	0.01198

Видео	Кадры	k	RMSV	AV
2+3	420	0.00	0.02890	0.01395
4+5	237	0.00	0.02838	0.00889

Таблица 6: Плавность предсказаний при слиянии для различных размеров окна в прокрустовом преобразовании ($k = 0$).

Видео	Размер окна	RMSV	AV
2+3	1	0.03183	0.00535
4+5	1	0.03089	0.00889

Видео	Размер окна	RMSV	AV
2+3	10	0.03100	0.00534
4+5	10	0.02958	0.00894

Видео	Размер окна	RMSV	AV
2+3	40	0.02936	0.00536
4+5	40	0.02847	0.00896

Видео	Размер окна	RMSV	AV
2+3	200	0.02936	0.00531
4+5	200	0.02839	0.00878

Видео	Размер окна	RMSV	AV
2+3	100	0.02936	0.00535
4+5	100	0.02838	0.00889

Данные в таблице 5 представлены для размера окна 100 в прокрустовом преобразовании.

Из таблицы 5 видно, что при резком переключении предсказаний с тех, что получены по видео 1, на те, что получены по видео 2 (т.е. при относительно больших k), результаты метрик наихудшие. Метрика RMSV, описывающая плавность движения, принимает наименьшие значения при $k = 0$, т.е. при весах $w_1 = w_2 = \frac{1}{2}$, на обеих парах видео. Метрика AV разброса длин расстояний между точками принимает наименьшие значения при $k = 0$ и $k = 0.01$ в зависимости от пары. Эти результаты косвенно показывают, что ансамблирование дает преимущество даже несмотря на то, что результаты базовых моделей по отдельности хуже, чем предсказания, полученные слиянием с динамическими весами. Ожидается, что при большем числе камер в конфигурации метрики можно улучшить еще больше.

Таблица 6 показывает, что значения AV практически неизменны в зависимости от ширины окна, используемого в рамках прокрустова преобразования. Одновременно с

этим, при увеличении ширины окна (начиная с единицы) значения RMSV уменьшаются до тех пор, пока ширина окна не будет сравнима с длиной шага (в кадрах). После этого RMSV практически не изменяется (окна ширины 40, 100, 200).

При совпадении метрик разумно взять как можно меньшую ширину окна в силу формулы (14). В датасете, использованном в данной работе, пациент движется в конкретном направлении, но если бы человек в кадре часто менял направление, это бы привело к ухудшению качества преобразованной позы, т.к. усреднение может приводить к искажениям (утрате жесткости скелета).

Примечание: в таблицах 5, 6 использованы предсказания поз в мультикамерной конфигурации, для которых синхронизация выполнена корректно.

Важной частью исследования являются анализ надежности предлагаемого алгоритма синхронизации и анализ возможности использования данных о движении для этого. Заметим, что не во всех случаях предложенный алгоритм синхронизации может в автоматическом режиме верно выбрать смещение. Это связано главным образом с расположением камер, но также и с периодичностью движения и шумом, всегда наличествующим в данных.

Приведем результаты работы алгоритма синхронизации при использовании различных фрагментов видео в рамках синхронизации и окон различной ширины для прокрустового преобразования при выравнивании поз.

Таблица 7: Работа алгоритма синхронизации. Первое видео пары урезано на 50 кадров с начала и конца.

Видео	Размер окна	Верно ли определено смещение?
2+3	1	Нет
4+5	1	Да

Видео	Размер окна	Верно ли определено смещение?
2+3	20	Нет
4+5	20	Да

Видео	Размер окна	Верно ли определено смещение?
2+3	100	Да
4+5	100	Да

Видео	Размер окна	Верно ли определено смещение?
2+3	200	Да
4+5	200	Да

Таблица 8: Работа алгоритма синхронизации. Первое видео пары урезано на 100 кадров с начала и конца.

Видео	Размер окна	Верно ли определено смещение?
2+3	1	Да
4+5	1	Нет

Видео	Размер окна	Верно ли определено смещение?
2+3	20	Да
4+5	20	Нет

Видео	Размер окна	Верно ли определено смещение?
2+3	100	Да
4+5	100	Нет

Видео	Размер окна	Верно ли определено смещение?
2+3	200	Да
4+5	200	Нет

Данные таблиц 7, 8 показывают, что в отдельных случаях синхронизация без дополнительного выбора из экстремумов вручную может быть ненадежна, т.к. ошибки на обоих парах возникают независимо от размера окна и количества вырезанных кадров. Это демонстрирует одно из ограничений модели. Заметим, что данный факт специфичен для датасета, используемого в рамках данной работы (движения периодичны, субъект и центры камер — примерно на одной прямой). В случае разнообразных движений и невырожденного расположения субъекта и камер минимум может быть явно выраженным и верно определяющим смещение (см. рис. 2).

В рамках экспериментального исследования в числе прочего были выполнены: визуальный анализ графиков, показывающих работу алгоритма синхронизации; попытка коррекции на скользящую среднюю для устранения систематического увеличения и уменьшения ошибок с течением времени из-за удаления (приближения) субъекта от камеры (к камере); анализ результатов при иных размерах окна; а также применение среднего квадратического вместо среднего арифметического в (15). Это также показало наличие ошибок при синхронизации для датасета, используемого в работе.

Вывод: в отдельных случаях наличие дополнительных механизмов синхронизации необходимо, хотя предлагаемый алгоритм и сокращает множество возможных смещений (см. множество минимумов на рис. 3).

4.4 Ограничения модели

Рис. 9 и рис. 10 демонстрируют одно из ограничений модели (всего пайплайна). На рис. 9, 10 представлены графики углов в коленях, вычисленных для восстановленной относительно трехмерной позы, для двух видео, запечатляющих одну и ту же сцену с человеком, идущим по длинному коридору, с выполненной синхронизацией во времени. В данном случае каждое из предсказаний получено по одной камере (монокулярные предсказания). В случае видео 1 человек движется по направлению от камеры, в случае видео 2 — к камере.




Рис. 9: Углы в коленях, видео 1. Более ранние кадры отвечают моментам времени, когда субъект находится ближе к камере.




Рис. 10: Углы в коленях, видео 2. Более ранние кадры отвечают моментам времени, когда субъект находится дальше от камеры.

Этот эффект связан в частности с ограниченной точностью восприятия глубины сцены моделью при увеличении расстояния от субъекта до камеры. В сочетании со снижением на расстоянии уверенности модели, обнаруживающей двумерные ключевые точки (см. таблицу 2), это свидетельствует о том, что при удалении человека от камеры реконструкция его позы меньше походит на его реальную позу в соответствующий момент времени. Отсюда также можно заключить, что метод слияния, предлагаемый в разделе 3.7.3, а также метод реконструкции трехмерной позы в мировых координатах, описанный в разделе 3.8.1, унаследуют это ограничение.

Как следствие вышесказанного, поза, получаемая в результате триангуляции (см. раздел 3.8.2), теоретически может быть точнее, нежели та, что получена в результате

монокулярного предсказания и та, что получена при последующем слиянии (с помощью усреднения) в случае нескольких камер.

В качестве примера приведем графики углов в коленях для одного из видео датасета CMU Raportic [29]. Рис. 11–14 представляют собой графики углов в коленях для различных способов предсказания позы, предложенных в рамках данной работы. Моменты времени синхронизированы, то есть кадр t для каждого графика отражает один и тот же момент времени в реальности.




Рис. 11: Углы в коленях; монокулярное предсказание с камеры 1.




Рис. 12: Углы в коленях; монокулярное предсказание с камеры 2.




Рис. 13: Углы в коленях; предсказание, полученное в результате слияния (усреднение).




Рис. 14: Углы в коленях; предсказание, полученное в результате триангуляции с использованием 2D точек.

Графики на рис. 11–13, в отличие от рис. 14, выглядят более «сглаженными». Этот эффект является результатом сглаживания, вносимого моделью для лифтинга MotionBERT (для митигации шумов в используемых 2D предсказаниях). Это свидетельствует о том, что если предположить полное отсутствие шума в двумерных предсказаниях (то есть полное совпадение предсказанных позиций ключевых точек с реальными), то максимально достижимая точность триангуляции будет больше, нежели точность предсказаний в остальных трех случаях, иллюстрируемых рис. 11–13.

Еще одним ограничением является необходимость выражения длин объектов (включая фокальные расстояния) в условных единицах. Это ограничение неустранимо без дополнительной информации о длине объектов на сцене в метрических единицах. Подтверждением этому служит, например, формула 33. Если домножить $(X, Y, Z)^T$ и t_j на коэффициент масштаба s , то проективное ограничение останется верным.

На примере графиков для длины голени (используем видео, упомянутое выше) проиллюстрируем наследование ошибки последующими элементами пайплайна от предыдущих. В идеализированном случае графики должны изображать константу.




Рис. 15: Длина левой голени.




Рис. 16: Длина правой голени.


Рис. 15, 16 иллюстрируют тот факт, что ошибочные предсказания двумерных точек приводят к ошибкам как в монокулярных предсказаниях (а следовательно, и в результатах слияния), так и в триангуляции. Причем триангуляция может неявно наследовать ошибку монокулярных предсказаний через потенциально неверно определенные фокальные расстояния (см. раздел 3.8.2).

Главное ограничение на применимость триангуляции задается относительным расположением камер и реконструируемой трехмерной точки в пространстве. Реконструкция осуществляется пересечением лучей, исходящих из центров камер. Прямой угол является оптимальным углом пересечения лучей в случае установки с двумя камерами, так как в такой конфигурации ошибка реконструкции из-за шума в 2D детекции минимальна. Ошибка реконструкции растет по мере удаления величины угла пересечения лучей от значения в 90 градусов [30] (при константных расстояниях от реконструируемой точки до камер).

4.5 Визуальные примеры реконструкции

В данном разделе представлены несколько иллюстраций результатов работы различных методов и элементов пайплайна.


На рис. 17, 18 приведен пример наложения трехмерных облаков точек (здесь — поз) с помощью прокрустова преобразования. Две позы соответственно отвечают одному и тому же моменту времени, но предсказаны по видео с разных камер.




Восстановленная относительная поза
для первого видео.

Восстановленная относительная поза
для второго видео.

Рис. 17: Относительные трехмерные позы до выравнивания с помощью прокрустова преобразования.



Наложение относительных поз с помощью прокрустова преобразования.



Уточненная в результате слияния относительная поза.

Рис. 18: Относительные трехмерные позы после наложения с помощью прокрустова преобразования.

На рис. 19, 20 представлен результат восстановления сцены с одной камерой, включающий оценку фокусного расстояния камеры и 3D позы в мировых координатах.




Рис. 19: Изображение трехмерной сцены. Зеленой меткой обозначена камера. Зеленым отрезком — оптическая ось.






Рис. 20: Сравнение репроекции восстановленной позы с оригинальными 2D предсказаниями.

На рис. 21, 22 представлен результат восстановления сцены с двумя камерами, включающий оценку параметров камер и оценку трехмерной позы в мировых координатах с помощью триангуляции.



Ракурс 1.



Ракурс 2.

Рис. 21: Изображение восстановленной трехмерной сцены при наличии двух камер с двух ракурсов. Зелеными метками обозначено положение камер в пространстве. Зелеными отрезками — направления оптических осей камер.




Рис. 22: Результат репроекции триангулированной позы с учетом предсказанных фокальных расстояний камер. По координатным осям отложены пиксели. Под двумерным предсказанием понимаются 2D точки, предсказанные по видео с помощью RTMPose, и использованные для триангуляции.

Заключение

В данной работе был реализован пайплайн для восстановления 3D позы человека из видео с использованием одной и нескольких камер. За основу метода восстановления трехмерной позы взяты SOTA-модели. Также были предложены методы сочетания различных элементов пайплайна таким образом, чтобы сделать итоговое предсказание пригодным для дальнейшей обработки.

Кроме того, были предложены методы оценки трехмерной позы в мировых координатах и оценки внутренних и внешних параметров камер на основе двумерных точек и относительной трехмерной позы, полученных на различных этапах обработки видео.

Проведенные эксперименты подтвердили корректность работы отдельных компонентов пайплайна. В условиях отсутствия эталонных (ground truth) данных, оценка итоговой относительной 3D позы проводилась визуально и показала плавность и правдоподобие реконструкции движений человека.

Исходный код проекта, включая результаты экспериментов, доступен в GitHub-репозитории¹.

¹<https://github.com/oscar-foxtrot/PoseBrew> (дата обращения: 15.05.2026)

А Приложение

А.1 Производная

$$\text{Для } t \in \{1, \dots, 243\} \quad G(t) = \exp \left(-\frac{1}{2} \left(\frac{(t-1) - 121}{40} \right)^2 \right)$$

$$\text{Для } t \in \{1, \dots, 81\} \quad G(t-81) = \exp \left(-\frac{1}{2} \left(\frac{(t+162-1) - 121}{40} \right)^2 \right)$$

$$\text{Для } t \in \{82, \dots, 243\} \quad G(t-81) = \exp \left(-\frac{1}{2} \left(\frac{(t-81-1) - 121}{40} \right)^2 \right)$$

$$\text{Для } t \in \{1, \dots, 162\} \quad G(t-162) = \exp \left(-\frac{1}{2} \left(\frac{(t+81-1) - 121}{40} \right)^2 \right)$$

$$\text{Для } t \in \{163, \dots, 243\} \quad G(t-162) = \exp \left(-\frac{1}{2} \left(\frac{(t-162-1) - 121}{40} \right)^2 \right)$$

Получим производную для $w_1(t)$ на $t \in \{82, \dots, 162\}$, рассматривая данную функцию как заданную на вещественных числах $t \in [82, 162]$:

$$\begin{aligned} w_1(t) &= \frac{\exp \left(-\frac{1}{2} \left(\frac{(t-1)-121}{40} \right)^2 \right)}{\exp \left(-\frac{1}{2} \left(\frac{(t-1)-121}{40} \right)^2 \right) + \exp \left(-\frac{1}{2} \left(\frac{(t-1-81)-121}{40} \right)^2 \right) + \exp \left(-\frac{1}{2} \left(\frac{(t-1+81)-121}{40} \right)^2 \right)} \\ w_1'(t) &= \frac{\left(\frac{61}{800} - \frac{t}{1600} \right) e^{-\frac{\left(\frac{t}{40} - \frac{61}{20} \right)^2}}}{e^{-\frac{\left(\frac{t}{40} - \frac{41}{40} \right)^2}} + e^{-\frac{\left(\frac{t}{40} - \frac{61}{20} \right)^2}} + e^{-\frac{\left(\frac{t}{40} - \frac{203}{40} \right)^2}}} + \\ &+ \frac{\left(-\left(\frac{41}{1600} - \frac{t}{1600} \right) e^{-\frac{\left(\frac{t}{40} - \frac{41}{40} \right)^2}} - \left(\frac{61}{800} - \frac{t}{1600} \right) e^{-\frac{\left(\frac{t}{40} - \frac{61}{20} \right)^2}} - \left(\frac{203}{1600} - \frac{t}{1600} \right) e^{-\frac{\left(\frac{t}{40} - \frac{203}{40} \right)^2}} \right) e^{-\frac{\left(\frac{t}{40} - \frac{61}{20} \right)^2}}}{\left(e^{-\frac{\left(\frac{t}{40} - \frac{41}{40} \right)^2}} + e^{-\frac{\left(\frac{t}{40} - \frac{61}{20} \right)^2}} + e^{-\frac{\left(\frac{t}{40} - \frac{203}{40} \right)^2}} \right)^2} = \\ &= e^{-\frac{\left(\frac{t}{40} - \frac{61}{20} \right)^2}} \cdot \left(\frac{\frac{61}{800} - \frac{t}{1600}}{e^{-\frac{\left(\frac{t}{40} - \frac{41}{40} \right)^2}} + e^{-\frac{\left(\frac{t}{40} - \frac{61}{20} \right)^2}} + e^{-\frac{\left(\frac{t}{40} - \frac{203}{40} \right)^2}}} + \right. \\ &\quad \left. + \frac{-\left(\frac{41}{1600} - \frac{t}{1600} \right) e^{-\frac{\left(\frac{t}{40} - \frac{41}{40} \right)^2}} - \left(\frac{61}{800} - \frac{t}{1600} \right) e^{-\frac{\left(\frac{t}{40} - \frac{61}{20} \right)^2}} - \left(\frac{203}{1600} - \frac{t}{1600} \right) e^{-\frac{\left(\frac{t}{40} - \frac{203}{40} \right)^2}}}{\left(e^{-\frac{\left(\frac{t}{40} - \frac{41}{40} \right)^2}} + e^{-\frac{\left(\frac{t}{40} - \frac{61}{20} \right)^2}} + e^{-\frac{\left(\frac{t}{40} - \frac{203}{40} \right)^2}} \right)^2} \right) \end{aligned}$$

Домножая на $\left(e^{-\frac{(\frac{t}{40}-\frac{41}{40})^2}{2}} + e^{-\frac{(\frac{t}{40}-\frac{61}{20})^2}{2}} + e^{-\frac{(\frac{t}{40}-\frac{203}{40})^2}{2}} \right)^2$,

а также сокращая на $e^{-\frac{(\frac{t}{40}-\frac{61}{20})^2}{2}}$ получаем:

$$\begin{aligned} & - \left(\frac{61}{800} - \frac{t}{1600} \right) e^{-\frac{(\frac{t}{40}-\frac{61}{20})^2}{2}} - \left(\frac{203}{1600} - \frac{t}{1600} \right) e^{-\frac{(\frac{t}{40}-\frac{203}{40})^2}{2}} + \\ & + \left(\frac{t}{1600} - \frac{41}{1600} \right) e^{-\frac{(\frac{t}{40}-\frac{41}{40})^2}{2}} + \left(\frac{61}{800} - \frac{t}{1600} \right) \left(e^{-\frac{(\frac{t}{40}-\frac{41}{40})^2}{2}} + e^{-\frac{(\frac{t}{40}-\frac{61}{20})^2}{2}} + e^{-\frac{(\frac{t}{40}-\frac{203}{40})^2}{2}} \right) \end{aligned}$$

Слагаемые с t сокращаются. Остается:

$$\frac{81 \left(-e^{\frac{81t}{800}} + e^{\frac{4941}{400}} \right) e^{-\frac{t^2}{3200} + \frac{41t}{1600} - \frac{41209}{3200}}}{1600} \quad (1A)$$

Это выражение равно нулю $\iff \left(-e^{\frac{81t}{800}} + e^{\frac{4941}{400}} \right) = 0 \iff \frac{81t}{800} = \frac{4941}{400} \iff 81t = 4941 \cdot 2 \iff t = 122$.

Заметим, что при получении выражения (1A) были использованы операции, не изменяющие нулей производной и ее знака. Отсюда, если $t > 122$, тогда $\frac{81t}{800} > \frac{4941}{400} \implies$ выражение (1A) < 0 . Аналогично, при $t < 122$ выражение > 0 .

Для $t \in \{1, \dots, 81\}$ (w_1 рассматривается как заданная на вещественных числах):

$$\begin{aligned} w_1(t) &= \frac{\exp \left(-\frac{1}{2} \left(\frac{(t-1)-121}{40} \right)^2 \right)}{\exp \left(-\frac{1}{2} \left(\frac{(t-1)-121}{40} \right)^2 \right) + \exp \left(-\frac{1}{2} \left(\frac{(t-1+162)-121}{40} \right)^2 \right) + \exp \left(-\frac{1}{2} \left(\frac{(t-1+81)-121}{40} \right)^2 \right)} \\ w_1'(t) &= \frac{81 \left(e^{\frac{81t}{1600} + \frac{1}{2}} + 2e^{\frac{1681}{3200}} \right) e^{-\frac{t^2}{3200} - \frac{t}{40} - \frac{3281}{3200}}}{1600} \end{aligned}$$

Это выражение всегда положительно.

Для $t \in \{163, \dots, 243\}$

$$w_1(t) = \frac{\exp \left(-\frac{1}{2} \left(\frac{(t-1)-121}{40} \right)^2 \right)}{\exp \left(-\frac{1}{2} \left(\frac{(t-1)-121}{40} \right)^2 \right) + \exp \left(-\frac{1}{2} \left(\frac{(t-1-81)-121}{40} \right)^2 \right) + \exp \left(-\frac{1}{2} \left(\frac{(t-1-162)-121}{40} \right)^2 \right)}$$

Выполняя шаги, аналогичные предыдущим, получаем:

$$w_1'(t) = \frac{81 \left(-e^{\frac{203t}{1600} + \frac{5041}{200}} - 2e^{\frac{71t}{400} + \frac{41209}{3200}} \right) e^{-\frac{t^2}{3200} - \frac{24373}{640}}}{1600}$$

Это выражение всегда отрицательно.

Заметим также, что $w_1(81) < w_1(82)$ и $w_1(162) > w_1(163)$

А.2 Формат Human3.6М




Рис. 23: Схема трехмерной позы в формате Human3.6М

На данном рисунке приведено схематичное изображение трехмерной позы в формате Human3.6М. Под множеством D «основных расстояний» подразумеваются пары точек, между которыми на данной схеме проведены отрезки.

Конкретно:

$$D = \{(3, 2), (2, 1), (1, 0), (0, 4), (4, 5), (5, 6), (13, 12), (12, 11), \\ (11, 8), (8, 14), (14, 15), (15, 16), (8, 9), (9, 10), (8, 7), (7, 0)\}$$

Список литературы

1. 2D Human Pose Estimation: New Benchmark and State of the Art Analysis / M. Andriluka [et al.] // 2014 IEEE Conference on Computer Vision and Pattern Recognition. — 2014. — P. 3686–3693.
2. 3D Human Pose Estimation in Video With Temporal Convolutions and Semi-Supervised Training / D. Pavlo [et al.] // 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2019. — P. 7745–7754.
3. *Aharon N., Orfaig R., Bobrovsky B.-Z.* BoT-SORT: Robust Associations Multi-Pedestrian Tracking. — 2022. — arXiv: 2206.14651 [cs.CV].
4. AlphaPose: Whole-Body Regional Multi-Person Pose Estimation and Tracking in Real-Time / H.-S. Fang [et al.] // IEEE Transactions on Pattern Analysis & Machine Intelligence. — Los Alamitos, CA, USA, 2023. — Vol. 45, no. 06. — P. 7157–7173.
5. Anatomy-Aware 3D Human Pose Estimation With Bone-Based Pose Decomposition / T. Chen [et al.] // IEEE Transactions on Circuits and Systems for Video Technology. — 2022. — Vol. 32, no. 1. — P. 198–209.
6. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding / J. Devlin [et al.] // Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers) / ed. by J. Burstein, C. Doran, T. Solorio. — Minneapolis, Minnesota : Association for Computational Linguistics, 2019. — P. 4171–4186.
7. *Bishop C. M.* Pattern Recognition and Machine Learning. — New York : Springer, 2006.
8. Deep High-Resolution Representation Learning for Visual Recognition / J. Wang [et al.] // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2021. — Vol. 43, no. 10. — P. 3349–3364.
9. Diagnosis of disease affecting gait with a body acceleration-based model using reflected marker data for training and a wearable accelerometer for implementation / M. Takallou, F. Fallahtafti, M. Hassan, [et al.] // Scientific Reports. — 2024. — Vol. 14. — P. 1075.
10. Exploiting Temporal Contexts With Strided Transformer for 3D Human Pose Estimation / W. Li [et al.] // IEEE Transactions on Multimedia. — 2023. — Vol. 25. — P. 1282–1293.

11. *Fischler M. A., Bolles R. C.* Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography // Communications of the ACM. — New York, NY, USA, 1981. — Vol. 24, no. 6. — P. 381–395.
12. *Forney G. D.* The Viterbi Algorithm // Proceedings of the IEEE. — 1973. — Vol. 61, no. 3. — P. 268–278.
13. Gait-based Parkinson’s disease diagnosis and severity classification using force sensors and machine learning / M. P. Navita, Y. Sharma, [et al.] // Scientific Reports. — 2025. — Vol. 15. — P. 328.
14. *Gower J. C.* Generalized Procrustes analysis // Psychometrika. — 1975. — Vol. 40, no. 1. — P. 33–51.
15. *Hartley R., Zisserman A.* Multiple View Geometry in Computer Vision. — 2nd ed. — Cambridge University Press, 2004.
16. *Hartley R. I.* In Defense of the Eight-Point Algorithm // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 1997. — Vol. 19, no. 6. — P. 580–593.
17. Human3.6M: Large Scale Datasets and Predictive Methods for 3D Human Sensing in Natural Environments / C. Ionescu [et al.] // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2014. — Vol. 36, no. 7. — P. 1325–1339.
18. *Kocabas M., Athanasiou N., Black M. J.* VIBE: Video Inference for Human Body Pose and Shape Estimation // 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2020. — P. 5252–5262.
19. *Kraft D.* A software package for sequential quadratic programming : Tech. Rep. / DLR German Aerospace Center – Institute for Flight Mechanics. — Cologne, Germany, 1988. — DFVLR-FB 88–28.
20. Large-Scale Datasets for Going Deeper in Image Understanding / J. Wu [et al.] // 2019 IEEE International Conference on Multimedia and Expo (ICME). — IEEE, 2019.
21. *Lin K., Wang L., Liu Z.* End-to-End Human Pose and Mesh Reconstruction with Transformers // 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2021. — P. 1954–1963.

22. Microsoft COCO: Common Objects in Context / T.-Y. Lin [et al.] // Computer Vision – ECCV 2014 / ed. by D. Fleet [et al.]. — Cham : Springer International Publishing, 2014. — P. 740–755.
23. MOTChallenge: A Benchmark for Single-Camera Multiple Target Tracking / P. Dendorfer [et al.] // International Journal of Computer Vision. — 2021. — Vol. 129, no. 4. — P. 845–881.
24. MotionBERT: A Unified Perspective on Learning Human Motion Representations / W. Zhu [et al.] // 2023 IEEE/CVF International Conference on Computer Vision (ICCV). — 2023. — P. 15039–15053.
25. *Myronenko A., Song X.* Point Set Registration: Coherent Point Drift // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2010. — Vol. 32, no. 12. — P. 2262–2275.
26. *Nelder J. A., Mead R.* A Simplex Method for Function Minimization // The Computer Journal. — 1965. — Vol. 7, no. 4. — P. 308–313.
27. Observation-Centric SORT: Rethinking SORT for Robust Multi-Object Tracking / J. Cao [et al.] // 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2023. — P. 9686–9696.
28. On Calibration of Modern Neural Networks / C. Guo [et al.] // Proceedings of the 34th International Conference on Machine Learning (ICML). — Sydney, NSW, Australia : JMLR.org, 2017. — P. 1321–1330. — (ICML 2017).
29. Panoptic Studio: A Massively Multiview System for Social Motion Capture / H. Joo [et al.] // 2015 IEEE International Conference on Computer Vision (ICCV). — 2015. — P. 3334–3342.
30. *Rahimian P., Kearney J.* Optimal Camera Placement for Motion Capture Systems in the Presence of Dynamic Occlusion // Proceedings of the 20th ACM Symposium on Virtual Reality Software and Technology. — 2015. — P. 129–138.
31. Recovering Accurate 3D Human Pose in the Wild Using IMUs and a Moving Camera / T. von Marcard [et al.] // Computer Vision – ECCV 2018 / ed. by V. Ferrari [et al.]. — Cham : Springer International Publishing, 2018. — P. 614–631.

32. RTMPose: Real-Time Multi-Person Pose Estimation based on MMPose / T. Jiang [et al.]. — 2023. — arXiv: 2303.07399 [cs.CV].
33. *Sampson P. D.* Fitting Conic Sections to "Very Scattered" Data: An Iterative Refinement of the Bookstein Algorithm // Computer Graphics and Image Processing. — 1982. — Vol. 18. — P. 97–108.
34. *Schönemann P. H.* A Generalized Solution of the Orthogonal Procrustes Problem // Psychometrika. — 1966. — Vol. 31, no. 1. — P. 1–10.
35. *Schönemann P. H., Carroll R. M.* Fitting one matrix to another under choice of a central dilation and a rigid motion // Psychometrika. — 1970. — Vol. 35, no. 2. — P. 245–255.
36. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python / P. Virtanen [et al.] // Nature Methods. — 2020. — Vol. 17. — P. 261–272.
37. *Stanojević V., Todorović B.* BoostTrack++: using tracklet information to detect more objects in multiple object tracking. — 2024. — arXiv: 2408.13003 [cs.CV].
38. *Szeliski R.* Computer Vision: Algorithms and Applications. — London : Springer, 2011.
39. *Umeyama S.* Least-squares estimation of transformation parameters between two point patterns // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 1991. — Vol. 13, no. 4. — P. 376–380.
40. ViTPose: Simple Vision Transformer Baselines for Human Pose Estimation / Y. Xu [et al.] // Advances in Neural Information Processing Systems. Vol. 35 / ed. by S. Koyejo [et al.]. — Curran Associates, Inc., 2022. — P. 38571–38584.
41. WHAM: Reconstructing World-Grounded Humans with Accurate 3D Motion / S. Shin [et al.] // 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2024. — P. 2070–2080.
42. *Whittle M. W.* Gait Analysis: An Introduction. — 4th ed. — Amsterdam : Butterworth-Heinemann, Elsevier, 2007.
43. Whole-Body Human Pose Estimation in the Wild / S. Jin [et al.] // Computer Vision – ECCV 2020 / ed. by A. Vedaldi [et al.]. — Cham : Springer International Publishing, 2020. — P. 196–214.

44. *Broström M.* BoxMOT: pluggable SOTA tracking modules for object detection, segmentation and pose estimation models [Электронный ресурс]. — 2023. — URL: <https://github.com/mikel-brostrom/boxmot> (дата обращения: 15.05.2026).
45. *MMPose Contributors.* OpenMMLab Pose Estimation Toolbox and Benchmark [Электронный ресурс]. — 2020. — URL: <https://github.com/open-mmlab/mmpose> (дата обращения: 15.05.2026).