

Реконструкция относительной трехмерной позы человека по необработанным видеоданным в условиях отсутствия метаданных

Фостенко Олег Андреевич, группа 411
Факультет вычислительной математики и кибернетики
МГУ им. М. В. Ломоносова, кафедра исследования операций

Научный руководитель:
к.ф.-м.н., доцент
Белянкин Г.А.

Москва, 2026

Оценка (восстановление) положения ключевых точек тела человека в пространстве важна для количественного анализа движений.

Большая часть современных подходов требует предварительной калибровки камер и использования специализированного оборудования.

В данной работе предлагается метод восстановления трехмерной позы, не требующий настройки и предъявляющий минимальные требования к оборудованию.

Цель


Разработать метод восстановления трехмерной позы человека по необработанным видеоданным без калибровки камер при наличии в качестве оборудования лишь одной или нескольких (двух) камер.

Цель. Монокулярный случай



Входной RGB-кадр

Источник: CMU Panoptic Dataset¹



Восстановленная
трехмерная поза и
оценка расположения камеры


¹ Panoptic Studio: A Massively Multiview System for Social Motion Capture. / H. Joo [et al.] // 2015 IEEE International Conference on Computer Vision (ICCV). 2015. P. 3334–3342

Цель. Случай режима стерео



Входные RGB-кадры

Источник: CMU Panoptic Dataset



Восстановленная трехмерная поза и расположение камер

Вход: видеоряд $V = (I_1, \dots, I_T)$, где $I_t \in \mathbb{R}^{H \times W \times 3}$ — t -й кадр.

Требуется построить способ обработки видео, включающий следующие этапы:

- 1 Оценка 2D позы (ключевые точки на видео):

$S = (S_1, \dots, S_T)$, S_t — 2D поза на t -м кадре:

$S_t = (p_t^1(I_t), \dots, p_t^K(I_t))$, $p_t^j = (u_t^j, v_t^j, c_t^j) \in \mathbb{R}^3$,

где p_t^j — тройка, характеризующая двумерную ключевую точку, в которой (u_t^j, v_t^j) — координаты точки в пиксельном пространстве на t -м кадре, c_j — уверенность модели на t -м кадре, K — число ключевых точек, описывающих 2D позу человека, $t = 1, \dots, T$.




RGB-кадр с наложением предсказанных положений ключевых точек на изображении

Источник оригинального изображения:
CMU Panoptic Dataset

- 2 Восстановление относительной трехмерной позы:

$$P = (P_1, \dots, P_T), \quad P_t \in \mathbb{R}^{3 \times M},$$

где M – число ключевых точек, описывающих 3D позу человека, $t = 1, \dots, T$.




Восстановленная относительная
трехмерная поза

Задачи


Относительная трехмерная поза — набор ключевых точек скелета, координата одной из которых фиксирована («корневая ключевая точка»). Особенностью большинства нейросетевых моделей является то, что они предсказывают позу именно в этом формате.

Глобальная трехмерная поза — трехмерная скелетная модель, не фиксированная в пространстве (в отличие от относительной позы).

- 3 Разработка метода оценки трехмерной позы в мировых координатах и параметров камеры при наличии одной камеры (монокулярный режим).
- 4 Разработка метода оценки трехмерной позы в мировых координатах и параметров камер при наличии двух камер (режим стерео).



Реконструкция. Монокулярный режим



Реконструкция. Режим стерео

Оценка относительной позы

Оценка 2D позы покaдpовo с помощью предобученной сверточной нейросети на базе CSPNeXt²



Оценка 3D позы на окнах фиксированной длины с помощью предобученной трансформерной модели на базе DSTFormer³



Временное сглаживание

Для подавления артефактов на стыках окон при предсказании трехмерной позы используется временное сглаживание с гауссовским ядром. Предсказания с перекрывающихся окон длины D усредняются с динамическими весами.

Гауссовское усреднение

Для t -го кадра: $G(t) = \exp\left(-\frac{(t \bmod D - \mu)^2}{2\sigma^2}\right)$

$$w_k(t) = \frac{G(t - t_k)}{\sum_{j=1}^3 G(t - t_j)}, \quad t_k = \frac{(k-1)D}{3}, \quad k \in \{1, 2, 3\}$$

² RTMPose: Real-Time Multi-Person Pose Estimation based on MMPose. / T. Jiang [et al.]. 2023. arXiv: 2303.07399 [cs.CV]

³ MotionBERT: A Unified Perspective on Learning Human Motion Representations. / W. Zhu [et al.] // 2023 IEEE/CVF International Conference on Computer Vision (ICCV). 2023. P. 15039–15053

Используемая модель

В работе для описания камер используется упрощенная модель камеры-обскуры. Для нее параметры задаются матрицей (1), где f — фокусное расстояние, H — вертикальное разрешение видео, W — горизонтальное разрешение видео.

$$K = \begin{pmatrix} f & 0 & \frac{W}{2} \\ 0 & f & \frac{H}{2} \\ 0 & 0 & 1 \end{pmatrix} \quad (1)$$

Глобальные координаты некоторой трехмерной точки $P_c = (X_c, Y_c, Z_c)^T$ (с камерой в начале координат и оптической осью, направленной вдоль оси OZ_c) связаны с пиксельными координатами этой точки (u, v) соотношением:

Связь между пиксельными и глобальными координатами

$$\begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = K \begin{pmatrix} \frac{X_c}{Z_c} \\ \frac{Y_c}{Z_c} \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{X_c}{Z_c} f + \frac{W}{2} \\ \frac{Y_c}{Z_c} f + \frac{H}{2} \\ 1 \end{pmatrix}$$

Восстановление глобальной позы в монокулярном режиме


Полагаем $Z_c \neq 0$. Тогда, зная глубину Z_c и пиксельные координаты (u, v) точки, можно восстановить ее трехмерные координаты:

Глобальные координаты, выраженные через пиксельные

$$X_c = \frac{u - \frac{W}{2}}{f} Z_c, \quad Y_c = \frac{v - \frac{H}{2}}{f} Z_c$$

$$Z_c = \frac{f}{h_i} h_c,$$

где h_c — реальный размер объекта (в глобальных координатах), h_i — размер объекта на изображении.



Восстановление глобальной позы в монокулярном режиме

Для относительной трехмерной позы есть точка, координата которой фиксирована и равна $(0, 0, 0)^T$ («корневая ключевая точка»).

Известен видимый размер $S(t)$ скелетной модели (он получен из видимого размера скелета на 2D изображении) в зависимости от кадра t .

Введем связь между глубиной корневой ключевой точки и видимым размером скелетной модели:

Глубина корневой ключевой точки в зависимости от времени

$$Z_c(t) = \frac{f}{S(t)} \cdot L, \quad L = \text{const.} \quad \text{Тогда} \quad Z_c(t) = \frac{\lambda}{S(t)},$$

λ — некоторый параметр. Отсюда следующая формула:

Глоб. координаты корневой точки при известных λ и f , выраженные через пиксельные

$$P_{root}(t) = (X_c^0(t), Y_c^0(t), Z_c^0(t))^T = \left(\frac{\lambda}{f \cdot S(t)} (u^0(t) - \frac{W}{2}), \frac{\lambda}{f \cdot S(t)} (v^0(t) - \frac{H}{2}), \frac{\lambda}{S(t)} \right)^T.$$

Восстановление глобальной позы в монокулярном режиме

На данном этапе известна относительная трехмерная поза, то есть набор трехмерных координат ключевых точек относительно корневой ключевой точки:

$$P_{rel}^i(t) = (X_{rel}^i(t), Y_{rel}^i(t), Z_{rel}^i(t))^T, \quad \text{где } i \text{ пробегает множество индексов ключевых точек}$$

Так, при известных λ и f известны 3D координаты всей позы: $P^i(t) = P_{rel}^i(t) + P_{root}(t) \quad \forall i$.

f выражается как функция от λ через решение задачи минимизации ошибки репроекции.

Согласно связи между глоб. и пиксельными координатами, каждой трехмерной точке с координатами $P^i(t)$ ставится в соответствие пара пиксельных координат $\pi(P^i(t)) = (\tilde{u}^i(t), \tilde{v}^i(t))$

Ошибка репроекции для i -й ключевой точки

$$E_i(f) = \sum_{t,i} \left\| \pi(P^i(t)) - (u^i(t), v^i(t)) \right\|^2, \quad (u^i(t), v^i(t)) \text{ — известные пиксельные координаты (предсказанные 2D детектором).}$$

Ошибка суммируется по всем точкам: $E(f) = \sum_i E_i(f)$.

Задача минимизации $E(f) \rightarrow \min_f$ имеет аналитическое решение.

Предлагается метод устранения неоднозначности, связанной с определением фокусного расстояния, основанный на том факте, что во время фазы опоры стопа человека должна быть почти неподвижна.

Последовательно решаются подзадачи:

- 1 Выделение интервалов времени, на которых человек осуществляет ходьбу (вводится метрика, учитывающая, в частности, асимметрию в высоте и скорости ног для предсказанной ранее относительной трехмерной позы. Далее отбираются кадры с метрикой выше заданного порога)
- 2 Выделяются фазы переноса и опоры отдельно для левой и правой ног (выполняется кластеризация с помощью модели гауссовых смесей (GMM)⁴). На выходе получаем вероятности того, что левая/правая нога находится в фазе опоры.
- 3 Далее вероятности преобразуются в метки $\{0, 1\}$, если текущий кадр соответствует фазе соответственно опоры или переноса.

⁴ *Bishop C. M.* Pattern Recognition and Machine Learning. New York : Springer, 2006.

Восстановление глобальной позы в монокулярном режиме

Вероятности GMM

$$p_k(t) = \mathbb{P}(z_t = k \mid x_t), \quad k \in \{0, 1\}.$$

Здесь $z_t \in \{0, 1\}$ — переменная, задающая принадлежность кадра t к одному из двух кластеров, x_t — наблюдаемый вектор признаков, k идентифицирует кластеры (каждый кластер как либо отвечающий фазам опоры, либо фазам переноса).

Полагаем $\mathbb{P}(z_t \mid z_{1:t-1}) := \mathbb{P}(z_t \mid z_{t-1}, z_{t-2}, \dots, z_1) = \mathbb{P}(z_t \mid z_{t-1})$.

Вероятности переходов (30 кадров/с)

$$a_{ij} = \mathbb{P}(z_t = j \mid z_{t-1} = i), \quad i, j \in \{0, 1\}; \quad A = \begin{pmatrix} 0.95 & 0.05 \\ 0.08 & 0.92 \end{pmatrix}$$

Максимально согласованная последовательность состояний

$$\hat{z}_{1:\tilde{T}} = \arg \max_{z_{1:\tilde{T}}} W(z_{1:\tilde{T}}), \quad \text{где } W(z_{1:\tilde{T}}) = \prod_{t=1}^{\tilde{T}} p_{z_t}(t) \prod_{t=2}^{\tilde{T}} a_{z_{t-1} z_t}.$$

Восстановление глобальной позы в монокулярном режиме

Задача поиска наиболее согласованной последовательности состояний сводится к задаче динамического программирования.

Пусть $V_t(j)$ обозначает максимальное значение функционала W для всех последовательностей длины t , заканчивающихся в состоянии j :

Функция Беллмана

$$V_t(j) = \max_{\substack{z_{1:t} \\ z_t=j}} W(z_{1:t}) \quad \left(W(z_{1:t}) = \prod_{s=1}^t p_{z_s}(s) \prod_{s=2}^t a_{z_{s-1} z_s} \right).$$

Тогда, в силу принципа оптимальности Беллмана:

Уравнение Беллмана





$$V_1(j) = p_j(1), \quad V_t(j) = \max_{i \in \{0,1\}} [V_{t-1}(i) a_{ij} p_j(t)], \quad t \geq 2.$$

Данное соотношение представляет собой уравнение Беллмана. Решение этой задачи осуществляется с использованием алгоритма Витерби⁵.

⁵ Forney G. D. The Viterbi Algorithm. // *Proceedings of the IEEE*. 1973. Vol. 61, no. 3. P. 268–278.

Восстановление глобальной позы в монокулярном режиме

Пример результата сегментации фаз опоры и переноса для некоторого видео:



(a) Вероятности фазы переноса для правой ноги;

(b) Вероятности фазы переноса для левой ноги;




(c) Восстановленная последовательность состояний для правой ноги;

(d) Восстановленная последовательность состояний для левой ноги.

Восстановление глобальной позы в монокулярном режиме

Далее минимизируемая метрика получается как сумма квадратов расстояний между позициями левой/правой стоп в начале, середине и конце фаз опоры для каждой фазы опоры.

Примеры ландшафта функции потерь (зависящей от параметра λ) для различных видео:



Восстановление глобальной позы в режиме стерео

Задача восстановления глобальной позы в режиме стерео отличается от монокулярного случая.

Общей является модель внутренних параметров камеры.

Для начала оба видео синхронизируются. Для этого в работе используется т.н. «прокрустово преобразование» (Procrustes analysis).

Задача Прокруста / Прокрустово преобразование

Пусть даны две матрицы $A, B \in \mathbb{R}^{n \times d}$. Требуется найти ортогональную матрицу $R \in \mathbb{R}^{d \times d}$, число $s \in \mathbb{R}$ и вектор переноса $t \in \mathbb{R}^d$ такие, что на них достигается

$$\min_{s, R, t} \|B - sAR - 1t^T\|_F^2$$

где $1 \in \mathbb{R}^n$ — вектор из единиц, и R удовлетворяет условию ортогональности: $R^T R = I$.
 1 и t есть вектор-столбцы.

Интуитивно, данное преобразование поворачивает, переносит и масштабирует одно облако точек относительно второго так, чтобы они были максимально похожи.

Каждая из матриц A и B в нашем случае будут таковы, что число строк равно числу точек скелетной модели, а по строкам записаны трехмерные координаты точек (в терминах относительной позы).

Восстановление глобальной позы в режиме стерео

Оптимальные R, t, s находятся в явной форме⁶:

1) Матрицы центрируются по столбцам:

$$\bar{A} = \frac{1}{n} A^T \mathbf{1}, \quad \bar{B} = \frac{1}{n} B^T \mathbf{1},$$

$$A_0 = A - \mathbf{1} \bar{A}^T, \quad B_0 = B - \mathbf{1} \bar{B}^T.$$

2) Из сингулярного разложения произведения матриц A_0^T, B_0 находится матрица R :

$$M = A_0^T B_0$$

$$M = U \Sigma V^T$$

$$R = UV^T$$


Примечание: Если $\det(R) < 0$, то имеем преобразование с отражением, но отражения не подходят по задаче. В этом случае последний столбец матрицы V умножается на -1 . Это позволяет дополнить алгоритм так, чтобы учитывать ограничение $\det(R) = 1$.

3) Находится оптимальный вектор переноса и масштаб:


$$t = \frac{1}{n} (B - sAR)^T \mathbf{1} = \bar{B} - sR^T \bar{A} = (\bar{B}^T - s\bar{A}^T R)^T, \quad s = \frac{\text{tr}(\Sigma)}{\|A_0\|_F^2}$$

⁶ *Myronenko A., Song X.* Point Set Registration: Coherent Point Drift. // IEEE Transactions on Pattern Analysis and Machine Intelligence. 2010. Vol. 32, no. 12. P. 2262–2275; *Schönmeyer P. H., Carroll R. M.* Fitting one matrix to another under choice of a central dilation and a rigid motion. // Psychometrika. 1970. Vol. 35, no. 2. P. 245–255; *Umeyama S.* Least-squares estimation of transformation parameters between two point patterns. // IEEE Transactions on Pattern Analysis and Machine Intelligence. 1991. Vol. 13, no. 4. P. 376–380.

Восстановление глобальной позы в режиме стерео



Пример наложения облаков точек (здесь — поз) с помощью прокрустового преобразования представлен на рисунке справа.




Восстановление глобальной позы в режиме стерео

Идея метода синхронизации: полагаем, что начало первого видео отстоит от начала второго на k кадров. Далее накладываем относительные позы, предсказанные по первому и второму видео, покадрово друг на друга (с учетом гипотетического смещения в k кадров).

Затем процедура повторяется для $k - 1$ кадра и т.д.

Для каждого смещения решается задача Прокруста, и получается некоторое значение минимума. Эти значения суммируются по всем кадрам, и данная сумма полагается значением метрики «схожести» двух видеорядов.

Пример вычисления метрики на некоторой паре видео для различных смещений представлен на рисунке справа. Далее считаем, что видео синхронизированы.



Восстановление глобальной позы в режиме стерео

Помимо внутренних параметров камер используется матрица внешних параметров $[R \mid t]$, задающая смещение и поворот одной камеры относительно другой.

Пусть некоторой 3D точке соответствуют координаты $(u_1, v_1), (u_2, v_2) \in R^2$ на двумерных изображениях, получаемых первой и второй камерами. Обозначим их однородные представления:

$$x_1 = (u_1, v_1, 1)^T, \quad x_2 = (u_2, v_2, 1)^T.$$

Эти точки связаны т.н. фундаментальной матрицей F :

$$x_1^T F x_2 = 0$$

F оценивается по 2D точкам с помощью 8-точечного алгоритма⁷ и метода RANSAC⁸.

При известных внутренних параметрах камер (f_1, f_2) вводится т.н. существенная матрица E :

$$E = K_2^T F K_1$$

Оценка на F при известных f_1, f_2 позволяет получить оценку на E , а из разложения E восстанавливаются R и t , после чего выполняется триангуляция⁹ (реконструкция) 3D позы.

⁷ Hartley R. I. In Defense of the Eight-Point Algorithm. // IEEE Transactions on Pattern Analysis and Machine Intelligence. 1997. Vol. 19, no. 6. P. 580–593

⁸ Fischler M. A., Bolles R. C. Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography. // Communications of the ACM. New York, NY, USA, 1981. Vol. 24, no. 6. P. 381–395.

⁹ Hartley R., Zisserman A. Multiple View Geometry in Computer Vision. 2nd ed. Cambridge University Press, 2004.


Восстановление глобальной позы в режиме стерео

Так, для фиксированных (f_1, f_2) имеем две позы: одна — глобальная, реконструированная с помощью триангуляции, другая — относительная, оцененная с помощью нейросети. Эти две позы сравниваются через прокрустово преобразование. Перебирая всевозможные пары (f_1, f_2) и находя для каждой из них значение минимума в задаче Прокруста при сравнении поз, получаем некоторую метрику «схожести» триангулированной глобальной позы и относительной априорной, оцененной с помощью нейросети.

Получаемую метрику назовем


«ошибка реконструкции».

Выражая $f_1 = e^{z_1}$, $f_2 = e^{z_2}$, получаем задачу безусловной оптимизации отн. (z_1, z_2) . В работе предлагается решать ее с помощью метода Нелдера-Мида¹⁰. Типичный ландшафт функции потерь визуализирован на рисунке справа (значения усечены сверху):




¹⁰ *Nelder J. A., Mead R.* A Simplex Method for Function Minimization. // *The Computer Journal.* 1965. Vol. 7, no. 4. P. 308–313

Результаты. Монокулярный режим




Исходный кадр с наложением двумерных поз

Источник оригинального видео: CMU Panoptic Dataset




Реконструированная трехмерная поза в мировых координатах

Результаты. Монокулярный режим




Исходный кадр с наложением двумерных поз

Источник оригинального видео: CMU Panoptic Dataset




Реконструированная трехмерная поза в мировых координатах

Результаты. Монокулярный режим




Исходный кадр с наложением двумерных поз

Источник оригинального видео: CMU Panoptic Dataset




Реконструированная трехмерная поза в мировых координатах

Результаты. Монокулярный режим




Исходный кадр с наложением двумерных поз

Источник оригинального видео: CMU Panoptic Dataset




Реконструированная трехмерная поза в мировых координатах

Результаты. Монокулярный режим




Исходный кадр с наложением двумерных поз

Источник оригинального видео: CMU Panoptic Dataset




Реконструированная трехмерная поза в мировых координатах

Результаты. Монокулярный режим




Исходный кадр с наложением двумерных поз

Источник оригинального видео: CMU Panoptic Dataset




Реконструированная трехмерная поза в мировых координатах

Результаты. Монокулярный режим




Исходный кадр с наложением двумерных поз

Источник оригинального видео: CMU Panoptic Dataset




Реконструированная трехмерная поза в мировых координатах

Результаты. Монокулярный режим






Исходный кадр с наложением двумерных поз

Источник оригинального видео: CMU Panoptic Dataset



Реконструированная трехмерная поза в мировых координатах



Результаты. Режим стерео



На рис. слева: исходные RGB-кадры с наложением двумерных поз.

На рис. сверху: реконструированная трехмерная поза в мировых координатах.




Результаты. Режим стерео



На рис. слева: исходные RGB-кадры с наложением двумерных поз.

На рис. сверху: реконструированная трехмерная поза в мировых координатах.




Результаты. Режим стерео



На рис. слева: исходные RGB-кадры с наложением двумерных поз.

На рис. сверху: реконструированная трехмерная поза в мировых координатах.




Результаты. Режим стерео



На рис. слева: исходные RGB-кадры с наложением двумерных поз.

На рис. сверху: реконструированная трехмерная поза в мировых координатах.




Результаты. Режим стерео



На рис. слева: исходные RGB-кадры с наложением двумерных поз.

На рис. сверху: реконструированная трехмерная поза в мировых координатах.




Результаты. Режим стерео



На рис. слева: исходные RGB-кадры с наложением двумерных поз.

На рис. сверху: реконструированная трехмерная поза в мировых координатах.




Результаты. Режим стерео



На рис. слева: исходные RGB-кадры с наложением двумерных поз.

На рис. сверху: реконструированная трехмерная поза в мировых координатах.

Результаты. Режим стерео




На рис. слева: исходные RGB-кадры с наложением двумерных поз.

На рис. сверху: реконструированная трехмерная поза в мировых координатах.

1 Для случая установки с двумя камерами (стерео):


- Синхронизация может быть выполнена некорректно, если движение человека на протяжении всего видео периодичное. На рисунке справа сверху графически представлен результат вычисления метрики похожести поз для различных смещений видео 1 относительно видео 2 для видео, на котором человек идет в одном направлении.
- При расположении центров двух камер и реконструируемых точек вблизи одной прямой на протяжении всего видео — зашумленная триангуляция и потенциально некорректное определение фокальных расстояний.



2 В случае установки с одной камерой:

- Неточное восстановление позы при большом удалении субъекта от камеры (в силу уменьшения точности восприятия глубины с удалением от камеры).

Имеет место наследование ошибок в 2D детекции относительной трехмерной позой, и ошибок в них обеих — реконструированной глобальной позой (рис. справа снизу изображает длину левой голени для нек-го предсказания — в реальности она должна быть почти константной).



В данной работе были предложены методы, в совокупности позволяющие оценить трехмерную позу человека из «сырых» (in-the-wild) видео.

- 1 Реализован (в виде программного комплекса) способ восстановления относительной 3D позы человека.
- 2 Предложен и реализован способ оценки трехмерной позы в мировых координатах при наличии установки с одной камерой.
- 3 Предложен и реализован способ оценки трехмерной позы в мировых координатах при наличии установки с двумя камерами.
- 4 Проведены численные эксперименты, позволившие оценить работоспособность предлагаемых методов.

1. 2D Human Pose Estimation: New Benchmark and State of the Art Analysis. /. — M. Andriluka [et al.] // 2014 IEEE Conference on Computer Vision and Pattern Recognition. — 2014. — P. 3686–3693.
2. 3D Human Pose Estimation in Video With Temporal Convolutions and Semi-Supervised Training. /. — D. Pavlo [et al.] // 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2019. — P. 7745–7754.
3. *Aharon N., Orfaig R., Bobrovsky B.-Z.* — BoT-SORT: Robust Associations Multi-Pedestrian Tracking. — 2022. — arXiv: 2206.14651 [cs.CV].
4. AlphaPose: Whole-Body Regional Multi-Person Pose Estimation and Tracking in Real-Time. /. — H.-S. Fang [et al.] // IEEE Transactions on Pattern Analysis & Machine Intelligence. — Los Alamitos, CA, USA, 2023. — Vol. 45, no. 06. — P. 7157–7173.
5. Anatomy-Aware 3D Human Pose Estimation With Bone-Based Pose Decomposition. /. — T. Chen [et al.] // IEEE Transactions on Circuits and Systems for Video Technology. — 2022. — Vol. 32, no. 1. — P. 198–209.

6. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. /. — J. Devlin [et al.] // Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers) / ed. by J. Burstein, C. Doran, T. Solorio. — Minneapolis, Minnesota : Association for Computational Linguistics, 2019. — P. 4171–4186.
7. *Bishop C. M.* — Pattern Recognition and Machine Learning. — New York : Springer, 2006.
8. Deep High-Resolution Representation Learning for Visual Recognition. /. — J. Wang [et al.] // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2021. — Vol. 43, no. 10. — P. 3349–3364.
9. Diagnosis of disease affecting gait with a body acceleration-based model using reflected marker data for training and a wearable accelerometer for implementation. /. — M. Takallou, F. Fallahtafi, M. Hassan, [et al.] // Scientific Reports. — 2024. — Vol. 14. — P. 1075.
10. Exploiting Temporal Contexts With Strided Transformer for 3D Human Pose Estimation. /. — W. Li [et al.] // IEEE Transactions on Multimedia. — 2023. — Vol. 25. — P. 1282–1293.
11. *Fischler M. A., Bolles R. C.* — Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography. — // Communications of the ACM. — New York, NY, USA, 1981. — Vol. 24, no. 6. — P. 381–395.

Список литературы III

12. *Forney G. D.* — The Viterbi Algorithm. — // *Proceedings of the IEEE*. — 1973. — Vol. 61, no. 3. — P. 268–278.
13. Gait-based Parkinson's disease diagnosis and severity classification using force sensors and machine learning. /. — M. P. Navita, Y. Sharma, [et al.] // *Scientific Reports*. — 2025. — Vol. 15. — P. 328.
14. *Gower J. C.* — Generalized Procrustes analysis. — // *Psychometrika*. — 1975. — Vol. 40, no. 1. — P. 33–51.
15. *Hartley R., Zisserman A.* — Multiple View Geometry in Computer Vision. — 2nd ed. — Cambridge University Press, 2004.
16. *Hartley R. I.* — In Defense of the Eight-Point Algorithm. — // *IEEE Transactions on Pattern Analysis and Machine Intelligence*. — 1997. — Vol. 19, no. 6. — P. 580–593.
17. Human3.6M: Large Scale Datasets and Predictive Methods for 3D Human Sensing in Natural Environments. /. — C. Ionescu [et al.] // *IEEE Transactions on Pattern Analysis and Machine Intelligence*. — 2014. — Vol. 36, no. 7. — P. 1325–1339.
18. *Kocabas M., Athanasiou N., Black M. J.* — VIBE: Video Inference for Human Body Pose and Shape Estimation. — // 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2020. — P. 5252–5262.

19. *Kraft D.* — A software package for sequential quadratic programming. — Tech. Rep. / DLR German Aerospace Center – Institute for Flight Mechanics. — Cologne, Germany, 1988. — DFVLR-FB 88–28.
20. Large-Scale Datasets for Going Deeper in Image Understanding. /. — J. Wu [et al.] // 2019 IEEE International Conference on Multimedia and Expo (ICME). — IEEE, 2019.
21. *Lin K., Wang L., Liu Z.* — End-to-End Human Pose and Mesh Reconstruction with Transformers. — // 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2021. — P. 1954–1963.
22. Microsoft COCO: Common Objects in Context. /. — T.-Y. Lin [et al.] // Computer Vision – ECCV 2014 / ed. by D. Fleet [et al.]. — Cham : Springer International Publishing, 2014. — P. 740–755.
23. MOTChallenge: A Benchmark for Single-Camera Multiple Target Tracking. /. — P. Dendorfer [et al.] // International Journal of Computer Vision. — 2021. — Vol. 129, no. 4. — P. 845–881.
24. MotionBERT: A Unified Perspective on Learning Human Motion Representations. /. — W. Zhu [et al.] // 2023 IEEE/CVF International Conference on Computer Vision (ICCV). — 2023. — P. 15039–15053.
25. *Myronenko A., Song X.* — Point Set Registration: Coherent Point Drift. — // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2010. — Vol. 32, no. 12. — P. 2262–2275.

26. *Nelder J. A., Mead R.* — A Simplex Method for Function Minimization. — // The Computer Journal. — 1965. — Vol. 7, no. 4. — P. 308–313.
27. Observation-Centric SORT: Rethinking SORT for Robust Multi-Object Tracking. /. — J. Cao [et al.] // 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2023. — P. 9686–9696.
28. On Calibration of Modern Neural Networks. /. — C. Guo [et al.] // Proceedings of the 34th International Conference on Machine Learning (ICML). — Sydney, NSW, Australia : JMLR.org, 2017. — P. 1321–1330. — (ICML 2017).
29. Panoptic Studio: A Massively Multiview System for Social Motion Capture. /. — H. Joo [et al.] // 2015 IEEE International Conference on Computer Vision (ICCV). — 2015. — P. 3334–3342.
30. *Rahimian P., Kearney J.* — Optimal Camera Placement for Motion Capture Systems in the Presence of Dynamic Occlusion. — // Proceedings of the 20th ACM Symposium on Virtual Reality Software and Technology. — 2015. — P. 129–138.
31. Recovering Accurate 3D Human Pose in the Wild Using IMUs and a Moving Camera. /. — T. von Marcard [et al.] // Computer Vision – ECCV 2018 / ed. by V. Ferrari [et al.]. — Cham : Springer International Publishing, 2018. — P. 614–631.

32. RTMPose: Real-Time Multi-Person Pose Estimation based on MMPose. /. — T. Jiang [et al.]. — 2023. — arXiv: 2303.07399 [cs.CV].
33. *Sampson P. D.* — Fitting Conic Sections to "Very Scattered" Data: An Iterative Refinement of the Bookstein Algorithm. — // *Computer Graphics and Image Processing*. — 1982. — Vol. 18. — P. 97–108.
34. *Schönemann P. H.* — A Generalized Solution of the Orthogonal Procrustes Problem. — // *Psychometrika*. — 1966. — Vol. 31, no. 1. — P. 1–10.
35. *Schönemann P. H., Carroll R. M.* — Fitting one matrix to another under choice of a central dilation and a rigid motion. — // *Psychometrika*. — 1970. — Vol. 35, no. 2. — P. 245–255.
36. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. /. — P. Virtanen [et al.] // *Nature Methods*. — 2020. — Vol. 17. — P. 261–272.
37. *Stanojević V., Todorović B.* — BoostTrack++: using tracklet information to detect more objects in multiple object tracking. — 2024. — arXiv: 2408.13003 [cs.CV].
38. *Szeliski R.* — Computer Vision: Algorithms and Applications. — London : Springer, 2011.
39. *Umeyama S.* — Least-squares estimation of transformation parameters between two point patterns. — // *IEEE Transactions on Pattern Analysis and Machine Intelligence*. — 1991. — Vol. 13, no. 4. — P. 376–380.

40. ViTPose: Simple Vision Transformer Baselines for Human Pose Estimation. /. — Y. Xu [et al.] // Advances in Neural Information Processing Systems. Vol. 35 / ed. by S. Koyejo [et al.]. — Curran Associates, Inc., 2022. — P. 38571–38584.
41. WHAM: Reconstructing World-Grounded Humans with Accurate 3D Motion. /. — S. Shin [et al.] // 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2024. — P. 2070–2080.
42. *Whittle M. W.* — Gait Analysis: An Introduction. — 4th ed. — Amsterdam : Butterworth-Heinemann, Elsevier, 2007.
43. Whole-Body Human Pose Estimation in the Wild. /. — S. Jin [et al.] // Computer Vision – ECCV 2020 / ed. by A. Vedaldi [et al.]. — Cham : Springer International Publishing, 2020. — P. 196–214.
44. *Broström M.* — BoxMOT: pluggable SOTA tracking modules for object detection, segmentation and pose estimation models [Электронный ресурс]. — 2023. — URL: <https://github.com/mikel-brostrom/boxmot> (дата обращения: 15.05.2026).
45. *MMPose Contributors.* — OpenMMLab Pose Estimation Toolbox and Benchmark [Электронный ресурс]. — 2020. — URL: <https://github.com/open-mmlab/mmpose> (дата обращения: 15.05.2026).