

Реконструкция относительной трехмерной позы человека по необработанным видеоданным в условиях отсутствия метаданных

Фостенко Олег Андреевич, группа 411
Факультет вычислительной математики и кибернетики
МГУ им. М. В. Ломоносова, кафедра исследования операций

Научный руководитель:
к.ф.-м.н., доцент
Белянкин Г.А.

Москва, 2026

Оценка (восстановление) положения ключевых точек тела человека в пространстве важна для количественного анализа движений.

Большая часть современных подходов требует предварительной калибровки камер и использования специализированного оборудования.

В данной работе предлагается метод восстановления трехмерной позы, не требующий настройки и предъявляющий минимальные требования к оборудованию.

Цель

Разработать метод восстановления трехмерной позы человека по необработанным видеоданным без калибровки камер при наличии в качестве оборудования лишь одной или нескольких (двух) камер.

<Блок с изображением некоторого кадра из видео>

<Блок с изображением трехмерных ключевых точек (визуализация Matplotlib, соответствующая кадру слева на данном слайде)>

Вход: видеоряд $V = (I_1, \dots, I_T)$, где $I_t \in \mathbb{R}^{H \times W \times 3}$ — t -й кадр.

Требуется построить способ обработки видео, включающий следующие этапы:

- 1 Оценка 2D позы (ключевые точки на видео):

$S = (S_1, \dots, S_T)$, S_t — 2D поза на t -м кадре:

$$S_t = (p_t^1(I_t), \dots, p_t^K(I_t)), \quad p_t^j = (u_t^j, v_t^j, c_t^j) \in \mathbb{R}^3,$$

где p_t^j — тройка, характеризующая двумерную ключевую точку, в которой (u_t^j, v_t^j) — координаты точки в пиксельном пространстве на t -м кадре, c_j — уверенность модели на t -м кадре, K — число ключевых точек, описывающих 2D позу человека, $t = 1, \dots, T$.

<Блок с изображением двумерной скелетной модели, наложенной на некоторый кадр из видео>

- 2 Восстановление относительной трехмерной позы:

$$P = (P_1, \dots, P_T), \quad P_t \in \mathbb{R}^{3 \times M},$$

где M – число ключевых точек, описывающих 3D позу человека, $t = 1, \dots, T$.

<Блок с изображением
трехмерной скелетной модели>

Относительная трехмерная поза — набор ключевых точек скелета без глобального положения в сцене.

Глобальная трехмерная поза — положение и ориентация в системе координат камеры.

- 3 Разработка метода оценки трехмерной позы в мировых координатах и параметров камеры при наличии одной камеры (монокулярный режим)
- 4 Разработка метода оценки трехмерной позы в мировых координатах и параметров камер при наличии двух камер (режим стерео).

<Блок с изображением трехмерной скелетной модели и положения камеры в монокулярном режиме>

<Блок с изображением трехмерной скелетной модели и положений камер в режиме стерео>

Оценка относительной позы

Для оценки 2D позы и получения относительной 3D позы используются нейросетевые модели.

< Простая диаграмма со следующим текстом: "Оценка 2D позы покадрово с помощью предобученной сверточной нейросети на базе CSPNeXt[библиограф. ссылка]" → "Оценка 3D позы на окнах фиксированной длины с помощью предобученной трансформерной модели на базе DSTFormer[библиограф. ссылка]" → "Временное сглаживание" >

Для подавления артефактов на стыках окон при предсказании трехмерной позы используется временное сглаживание с гауссовским ядром. Предсказания с перекрывающихся окон длины D усредняются с динамическими весами.

Гауссовское усреднение

Для t -го кадра: $G(t) = \exp\left(-\frac{(t \bmod D - \mu)^2}{2\sigma^2}\right)$

$$w_k(t) = \frac{G(t - t_k)}{\sum_{j=1}^3 G(t - t_j)}, \quad t_k = \frac{(k-1)D}{3}, \quad k \in \{1, 2, 3\}$$

<Диаграмма, графически показывающая значения динамических весов на перекрывающихся окнах с визуализацией в виде гауссовских "колоколов"(как здесь, сверху <http://www.ai.mit.edu/courses/6.892/lect14-html/sld017.gif>) >

Используемая модель

В работе для описания камер используется упрощенная модель камеры-обскуры. Для нее параметры задаются матрицей (1). где f — фокусное расстояние, H — вертикальное разрешение видео, W — горизонтальное разрешение видео.

$$K = \begin{pmatrix} f & 0 & \frac{W}{2} \\ 0 & f & \frac{H}{2} \\ 0 & 0 & 1 \end{pmatrix} \quad (1)$$

Глобальные координаты некоторой трехмерной точки $P_c = (X_c, Y_c, Z_c)^T$ (с камерой в начале координат и оптической осью, направленной вдоль оси OZ_c) связаны с пиксельными координатами этой точки (u, v) соотношением:

Связь между пиксельными и глобальными координатами

$$\begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = K \begin{pmatrix} \frac{X_c}{Z_c} \\ \frac{Y_c}{Z_c} \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{X_c}{Z_c} f + \frac{W}{2} \\ \frac{Y_c}{Z_c} f + \frac{H}{2} \\ 1 \end{pmatrix}$$

Восстановление глобальной позы в монокулярном режиме


Полагаем $Z_c \neq 0$. Тогда, зная глубину Z_c и пиксельные координаты (u, v) точки, можно восстановить ее трехмерные координаты:

Глобальные координаты, выраженные через пиксельные

$$X_c = \frac{u - \frac{W}{2}}{f} Z_c, \quad Y_c = \frac{v - \frac{H}{2}}{f} Z_c$$

$$Z_c = \frac{f}{h_i} h_c,$$

где h_c — реальный размер объекта (в глобальных координатах), h_i — размер объекта на изображении.



Восстановление глобальной позы в монокулярном режиме

Для относительной трехмерной позы есть точка, координата которой фиксирована и равна $(0, 0, 0)^T$. Назовем ее «**корневая ключевая точка**».

Известен видимый размер $S(t)$ скелетной модели (он получен из видимого размера скелета на 2D изображении) в зависимости от кадра t .

Введем связь между глубиной корневой ключевой точки и видимым размером скелетной модели:

Глубина корневой ключевой точки в зависимости от времени

$$Z_c(t) = \frac{f}{S(t)} \cdot L, \quad L = \text{const.} \quad \text{Тогда} \quad Z_c(t) = \frac{\lambda}{S(t)},$$

λ — некоторый параметр. Отсюда следующая формула:

Глоб. координаты корневой точки при известных λ и f , выраженные через пиксельные

$$P_{root}(t) = (X_c^0(t), Y_c^0(t), Z_c^0(t))^T = \left(\frac{\lambda}{f \cdot S(t)} (u^0(t) - \frac{W}{2}), \frac{\lambda}{f \cdot S(t)} (v^0(t) - \frac{H}{2}), \frac{\lambda}{S(t)} \right)^T.$$

Восстановление глобальной позы в монокулярном режиме

На данном этапе известна относительная трехмерная поза, то есть набор трехмерных координат ключевых точек относительно корневой ключевой точки:

$$P_{rel}^i(t) = (X_{rel}^i(t), Y_{rel}^i(t), Z_{rel}^i(t))^T, \quad \text{где } i \text{ пробегает множество индексов ключевых точек}$$

Так, при известных λ и f известны 3D координаты всей позы: $P^i(t) = P_{rel}^i(t) + P_{root}(t) \quad \forall i$.

f выражается как функция от λ через решение задачи минимизации ошибки репроекции.

Согласно связи между глоб. и пиксельными координатами, каждой трехмерной точке с координатами $P^i(t)$ ставится в соответствие пара пиксельных координат $\pi(P^i(t)) = (\tilde{u}^i(t), \tilde{v}^i(t))$

Ошибка репроекции для i -й ключевой точки

$$E_i(f) = \sum_{t,i} \left\| \pi(P^i(t)) - (u^i(t), v^i(t)) \right\|^2, \quad (u^i(t), v^i(t)) \text{ — известные пиксельные координаты (предсказанные 2D детектором).}$$

Ошибка суммируется по всем точкам: $E(f) = \sum_i E_i(f)$.

Задача минимизации $E(f) \rightarrow \min_f$ имеет аналитическое решение.

Восстановление глобальной позы в монокулярном режиме

Предлагается метод устранения неоднозначности, связанной с определением фокусного расстояния, основанный на том факте, что во время фазы опоры стопа человека должна быть почти неподвижна.

Последовательно решаются подзадачи:

- 1 Выделение интервалов времени, на которых человек осуществляет ходьбу (Вводится метрика, учитывающая, в частности, асимметрию в высоте и скорости ног для предсказанной ранее относительной трехмерной позы. Далее отбираются кадры с метрикой выше заданного порога)
- 2 Выделяются фазы маха и опоры отдельно для левой и правой ног (выполняется кластеризация с помощью модели гауссовых смесей (GMM)). На выходе получаем вероятности того, что левая/правая нога находится в фазе опоры.
- 3 Далее вероятности преобразуются в метки $\{0, 1\}$, если текущий кадр соответствует фазе соответственно опоры или маха.

<Диаграмма, изображающая фазы опоры и маха с указанием их длительности>

Восстановление глобальной позы в монокулярном режиме

Формально, GMM дает вероятности:

Вероятности GMM

$$p_k(t) = \mathbb{P}(z_t = k \mid x_t), \quad k \in \{0, 1\}.$$

Здесь $z_t \in \{0, 1\}$ — переменная, задающая принадлежность кадра t к одному из двух кластеров, x_t — наблюдаемый вектор признаков, k идентифицирует кластеры (каждый кластер как либо отвечающий фазам опоры, либо фазам маха).

Предполагается, что последовательность $\{z_t\}$ обладает свойством:

$$\mathbb{P}(z_t \mid z_{1:t-1}) := \mathbb{P}(z_t \mid z_{t-1}, z_{t-2}, \dots, z_1) = \mathbb{P}(z_t \mid z_{t-1}).$$

На основании сведений о средней длительности фаз опоры и маха и известной кадровой частоты видео (30 кадров/с) вводится матрица переходных вероятностей:

Вероятности переходов

$$a_{ij} = \mathbb{P}(z_t = j \mid z_{t-1} = i), \quad i, j \in \{0, 1\}; \quad A = \begin{pmatrix} 0.95 & 0.05 \\ 0.08 & 0.92 \end{pmatrix}$$

Восстановление глобальной позы в монокулярном режиме

Вводится метрика, минимизируя которую, можно найти максимально «согласованную» последовательность состояний z_t по всем кадрам:

Максимально согласованная последовательность состояний

$$\hat{z}_{1:\tilde{T}} = \arg \max_{z_{1:\tilde{T}}} W(z_{1:\tilde{T}}), \text{ где } W(z_{1:\tilde{T}}) = \prod_{t=1}^{\tilde{T}} p_{z_t}(t) \prod_{t=2}^{\tilde{T}} a_{z_{t-1}z_t}.$$

Здесь перемножаются вероятности, получаемые с помощью *GMM*, и вероятности переходов между состояниями 0 и 1 (опора и max).





Данная задача решается как динамического программирования.

Уравнение Беллмана

$$V_t(j) = \max_{\substack{z_{1:t} \\ z_t=j}} W(z_{1:t}) \iff V_t(j) = \max_{i \in \{0,1\}} [V_{t-1}(i) a_{ij} p_j(t)].$$

Восстановление глобальной позы в монокулярном режиме

Пример результата сегментации фаз опоры и маха для некоторого видео:






- (a) Вероятности фазы маха для правой ноги;
- (b) Вероятности фазы маха для левой ноги;
- (c) Восстановленная последовательность состояний для правой ноги;
- (d) Восстановленная последовательность состояний для левой ноги.

Восстановление глобальной позы в монокулярном режиме

Далее минимизируемая метрика получается как сумма квадратов расстояний между позициями левой/правой стоп в начале, середине и конце фаз опоры для каждой фазы опоры.

Примеры ландшафта функции потерь (зависящей от параметра λ) для различных видео:



Восстановление глобальной позы в режиме стерео

Задача восстановления глобальной позы в режиме стерео отличается от монокулярного случая. Общей является модель внутренних параметров камеры. Для начала оба видео синхронизируются. Для этого в работе используется т.н. «прокрустово преобразование» (Procrustes analysis).

Задача Прокруста / Прокрустово преобразование

Пусть даны две матрицы $A, B \in \mathbb{R}^{n \times d}$. Требуется найти ортогональную матрицу $R \in \mathbb{R}^{d \times d}$, число $s \in \mathbb{R}$ и вектор переноса $t_{\text{trans}} \in \mathbb{R}^d$ такие, что на них достигается

$$\min_{s, R, t_{\text{trans}}} \|B - sAR - 1t_{\text{trans}}^T\|_F^2$$

где $1 \in \mathbb{R}^n$ — вектор из единиц, и R удовлетворяет условию ортогональности: $R^T R = I$. 1 и t_{trans} есть вектор-столбцы.

Интуитивно, данное преобразование поворачивает, переносит и масштабирует одно облако точек относительно второго так, чтобы они были максимально похожи.

Каждая из матриц A и B в нашем случае будут таковы, что число строк равно числу точек скелетной модели, а по строкам записаны трехмерные координаты точек (в терминах относительной позы).

Восстановление глобальной позы в режиме стерео

Оптимальные R, t, s находятся в явной форме: <цитата Schonemann, Carroll>

1) Матрицы центрируются по столбцам:

$$\bar{A} = \frac{1}{n} A^T \mathbf{1}, \quad \bar{B} = \frac{1}{n} B^T \mathbf{1},$$

$$A_0 = A - \mathbf{1} \bar{A}^T, \quad B_0 = B - \mathbf{1} \bar{B}^T.$$

2) Из сингулярного разложения произведения матриц A_0^T, B_0 находится матрица R :

$$M = A_0^T B_0$$

$$M = U \Sigma V^T$$

$$R = UV^T$$

Примечание: Если $\det(R) < 0$, то имеем преобразование с отражением, но отражения не подходят по задаче. В этом случае последний столбец матрицы V умножается на -1 . Это позволяет дополнить алгоритм так, чтобы учитывать ограничение $\det(R) = 1$ <цитата Schonemann, Carroll>.

3) Находится оптимальный вектор переноса и масштаб:

$$t_{\text{trans}} = \frac{1}{n} (B - sAR)^T \mathbf{1} = \bar{B} - sR^T \bar{A} = (\bar{B}^T - s\bar{A}^T R)^T, \quad s = \frac{\text{tr}(\Sigma)}{\|A_0\|_F^2}$$


Восстановление глобальной позы в режиме стерео

Идея метода синхронизации: полагаем, что начало первого видео отстоит от начала второго на k кадров. Далее накладываем относительные позы, предсказанные по первому и второму видео, покадрово друг на друга (с учетом гипотетического смещения в k кадров).

Затем процедура повторяется для $k - 1$ кадра и т.д.

Для каждого смещения решается задача прокруста, и получается некоторое значение минимума. Эти значения суммируются по всем кадрам, и данная сумма полагается значением метрики «схожести» двух видеорядов.

Пример вычисления метрики на одном из видео для различных смещений:



Восстановление глобальной позы в режиме стерео

Далее считаем, что видео синхронизированы.

В качестве параметров камеры теперь выступает не только матрица внутренних параметров, введенная ранее, но также и матрица внешних параметров, задающая ее смещение в пространстве и поворот.

Пусть есть трехмерная точка $(X, Y, Z)^T \in R^3$ и соответствующие ей точки $(u_1, v_1), (u_2, v_2) \in R^2$ на двумерных изображениях, получаемых первой и второй камерами. Соответственно обозначим их однородные представления:

$$\tilde{X} = (X, Y, Z, 1)^T, \quad x_1 = (u_1, v_1, 1)^T, \quad x_2 = (u_2, v_2, 1)^T.$$

Введем для двух камер так называемые матрицы проекции:

$$P_1 = K_1[R_1 \mid t_1], \quad P_2 = K_2[R_2 \mid t_2].$$

Тогда из соотношения между трехмерными и пиксельными координатами имеем:

$$\lambda_j x_j = P_j \tilde{X}, \text{ или } x_j \sim K_j(R_j(X, Y, Z)^T + t_j), \quad j = 1, 2.$$

Восстановление глобальной позы в режиме стерео

Стоит задача восстановить трехмерную позу в каких-либо глобальных координатах.

Положим $R_1 = I$ (I — единичная матрица), $t_1 = 0$. $R := R_2$, $t := t_2$.

Пусть $\bar{X}_c^1 = (X_c^1, Y_c^1, Z_c^1)^T$ — координаты некоторой трехмерной точки в мировой системе координат относительно первой камеры. $\bar{X}_c^2 = (X_c^2, Y_c^2, Z_c^2)^T$ — координаты той же точки относительно второй камеры. Под мировой относительно камеры системой координат понимается та, где камера находится в точке начала отсчета, а оптическая ось направлена вдоль Oz .

Влияние поворота и переноса второй камеры относительно первой на связь трехмерных координат точки в двух глобальных СК, связанных с 1й и 2й камерами

$$\bar{X}_c^2 = R\bar{X}_c^1 + t$$

Выполняется переход в т.н. «нормализованные» координаты (если известны фокальные расстояния f_1 первой камеры и f_2 второй камеры):

$$\hat{x}_j = \left(\frac{X_c^j}{Z_c^j}, \frac{Y_c^j}{Z_c^j}, 1 \right)^T = K_j^{-1} x_j, \quad j = 1, 2.$$

Восстановление глобальной позы в режиме стерео

Геометрически три вектора $\hat{x}_1$, $\hat{x}_2$, t лежат в одной плоскости (эпиполярной плоскости). Следовательно, их смешанное произведение равно нулю.

Введем матричное представление векторного произведения. Для любого вектора $t = (t_1, t_2, t_3)^T$ определим матрицу $[t]_{\times}$ вида (2).

Так, получаем

$$t \times (R\hat{x}_1) = [t]_{\times} R\hat{x}_1.$$

Тогда справедлива формула:

$$\hat{x}_2^T [t]_{\times} R\hat{x}_1 = 0.$$

Определим так называемую фундаментальную матрицу:

$$F = K_2^{-T} [t]_{\times} R K_1^{-1}.$$

Возвращаясь к пиксельным координатам x_1, x_2 , получаем так называемое эпиполярное ограничение:

$$x_1^T F x_2 = 0.$$

$$\hat{x}_2^T (t \times (R\hat{x}_1)) = 0$$

$$[t]_{\times} = \begin{pmatrix} 0 & -t_3 & t_2 \\ t_3 & 0 & -t_1 \\ -t_2 & t_1 & 0 \end{pmatrix} \quad (2)$$

Матрица F оценивается через соответствия $(x_1^i(t), x_2^i(t))$ точек в пиксельных координатах для первой и второй камер с использованием 8-точечного алгоритма<цитата 8-точечный алгоритм> и метода RANSAC<цитата RANSAC>.

При известных фокусных расстояниях f_1, f_2 введем матрицу:

$$\hat{E} = K_2^T \hat{F} K_1, \quad \hat{F} — \text{оценка фундаментальной матрицы}$$

Заметим, что при верно выбранных фокальных расстояниях выполнено:

$$\hat{E} \approx [t]_{\times} R.$$

Оценки R и t восстанавливаются через $\hat{E}$ с помощью сингулярного разложения.

После восстановления R и t (напомним, f_1 и f_2 полагаются фиксированными) поза реконструируется с помощью т.н. триангуляции<цитата триангуляция>.

Восстановление глобальной позы в режиме стерео

Так, для фиксированных (f_1, f_2) имеем две позы: одна — глобальная, реконструированная с помощью триангуляции, другая — относительная, оцененная с помощью нейросети. Эти две позы сравниваются через прокрустово преобразование. Перебирая всевозможные пары (f_1, f_2) и находя для каждой из них значение минимума в задаче прокруста при сравнении поз, получаем некоторую метрику «схожести» триангулированной глобальной позы и относительной априорной, оцененной с помощью нейросети.

задачу безусловной оптимизации отн. (z_1, z_2) . В работе предлагается решать ее с помощью метода

Нелдера-Мида <читается Nelder-Mead>.

Выражая $d_1 = e_1, d_2 = e_1$, получаем. Типичный ландшафт функции потерь визуализирован на рисунке ниже:

